



Universidad
Internacional
de Valencia

Análisis bioinformático de expresión génica en adenocarcinoma pancreático: identificación de biomarcadores pronósticos mediante análisis diferencial, redes de coexpresión y modelo de supervivencia LASSO-Cox.

Titulación:

Máster en Bioinformática

Curso académico

2025 – 2026

Alumno/a: Torres Marcos, Inés

D.N.I.: 77043656G

Director/a de TFM:

Dulcenombrede María del Saz
Navarro

Convocatoria: Segunda

De:

 Planeta Formación y Universidades

ÍNDICE

LISTA DE ABREVIATURAS.....	3
ÍNDICE DE TABLAS & FIGURAS.....	5
RESUMEN.....	7
ABSTRACT.....	7
1. Introducción.....	8
1.1. Contexto y justificación.....	8
1.2. Biología molecular del PDAC.....	8
1.3. Biomarcadores en cáncer de páncreas.....	10
1.4. Estado del arte.....	11
2. Hipótesis y objetivos.....	12
2.1. Hipótesis.....	12
2.2. Objetivo general.....	12
3. Materiales y métodos.....	13
3.1. Fuentes de datos y tecnología de secuenciación.....	13
3.2. Preprocesamiento e integración de datos.....	14
3.3. Análisis de expresión diferencial con DESeq2.....	15
3.4. Análisis de redes de coexpresión génica (WGCNA).....	15
3.5. Integración y selección de genes clave.....	16
3.6. Validación con genes conocidos de PDAC.....	16
3.7. Análisis de supervivencia.....	17
3.8. Modelo LASSO-Cox.....	17
3.9. Anotación funcional de la firma pronóstica.....	18
3.10. Scripts.....	18
4. Resultados.....	18
4.1. Preprocesamiento e integración de datos.....	19
4.2. Análisis de expresión diferencial.....	21
4.3. Red de coexpresión génica (WGCNA).....	24
4.4. Integración DEGs y genes hub.....	27
4.5. Análisis de supervivencia.....	31
4.6. Firma pronóstica LASSO-Cox.....	32
4.7. Anotación funcional de la firma pronóstica.....	36
5. Discusión.....	39
5.1. Expresión diferencial.....	39
5.2. Módulos de coexpresión y su significado funcional.....	40
5.3. Genes clave y análisis de supervivencia.....	40
5.4. Firma pronóstica LASSO-Cox.....	41
5.5. Validación con genes de referencia.....	43
5.6. Limitaciones.....	43
5.7. Perspectivas futuras.....	44

6. Conclusiones.....	44
7. Referencias.....	45
7.1 Declaración de uso de Inteligencia Artificial.....	51
8. Anexo.....	52

LISTA DE ABREVIATURAS

Tabla 0. Lista de abreviaturas.

Abreviatura	Significado	Traducción al español (si aplica)
AChE	<i>Acetylcholinesterase</i>	Acetilcolinesterasa
DNA	<i>Deoxyribonucleic Acid</i>	Ácido Desoxirribonucleico
ARN	<i>Ribonucleic Acid</i>	Ácido Ribonucleico
mRNA	<i>Messenger RNA</i>	RNA mensajero
AUC	<i>Area Under the Curve</i>	Área Bajo la Curva
C-index	<i>Concordance Index</i>	Índice de Concordancia
CA19-9	<i>Carbohydrate Antigen 19-9</i>	Antígeno Carbohidrato 19-9
CAFs	<i>Cancer-Associated Fibroblasts</i>	Fibroblastos Asociados al Cáncer
CDK1	<i>Cyclin Dependent Kinase 1</i>	Quinasa dependiente de ciclina 1
CDK4/6	<i>Cyclin-Dependent Kinase 4/6</i>	Quinasa Dependiente de Ciclina 4/6
CEA	<i>Carcinoembryonic Antigen</i>	Antígeno Carcinoembrionario
ceRNA	<i>Competing Endogenous RNA</i>	RNA Endógeno Competitivo
COL1A1	<i>Collagen Type I Alpha 1 Chain</i>	Cadena alfa 1 del colágeno tipo I
DEGs	<i>Differentially Expressed Genes</i>	Genes Diferencialmente Expresados
DESeq2	<i>Differential Expression analysis for Sequence count data (version 2)</i>	Análisis de secuencias de expresión diferencial
DPC4	<i>Deleted in Pancreatic Cancer 4</i>	Delecionado en Cáncer de Páncreas 4 (alias de SMAD4)
eIF4F	<i>Eukaryotic Initiation Factor 4F</i>	Factor de Iniciación Eucariótico 4F
FDA	<i>Food and Drug Administration</i>	Administración de Alimentos y Medicamentos (EE. UU.)
FDR	<i>False Discovery Rate</i>	Tasa de Falsos Descubrimientos
GDC	<i>Genomic Data Commons</i>	Repositorio de Datos Genómicos
GEO	<i>Gene Expression Omnibus</i>	Repositorio de Expresión Génica
GO	<i>Gene Ontology</i>	Ontología Génica
GS	<i>Gene Significance</i>	Significación Génica

GTE _x	<i>Genotype-Tissue Expression Project</i>	Proyecto de Expresión Genotipo-Tejido
HGF/MET	<i>Hepatocyte Growth Factor</i>	Factor de crecimiento hepatocitario
HGNC	<i>HUGO Gene Nomenclature Committee</i>	Comité de Nomenclatura Génica HUGO
HR	<i>Hazard Ratio</i>	Razón de Riesgos Instantáneos
IC	<i>Intervalo de Confianza</i>	-
ICGC	<i>International Cancer Genome Consortium</i>	Consortio Internacional del Genoma del Cáncer
IQR	<i>Interquartile Range</i>	Rango Intercuartílico
IRF3	<i>Interferon Regulatory Factor 3</i>	Factor Regulador del Interferón 3
KEGG	<i>Kyoto Encyclopedia of Genes and Genomes</i>	Enciclopedia de Genes y Genomas de Kioto
kME	<i>Module Membership</i>	Pertenencia al Módulo
LASSO	<i>Least Absolute Shrinkage and Selection Operator</i>	Operador de Selección y Contracción Mínima Absoluta
lncRNA	<i>Long Non-Coding RNA</i>	RNA Largo No Codificante
log ₂ FC	<i>Log₂ Fold Change</i>	Logaritmo en Base 2 del Cambio de Expresión
MAD	<i>Median Absolute Deviation</i>	Desviación Absoluta Mediana
MAPK	<i>Mitogen-Activated Protein Kinase</i>	Proteína Quinasa Activada por Mitógenos
MAVS	<i>Mitochondrial Antiviral Signaling Protein</i>	Proteína de señalización antiviral mitocondrial
MDSCs	<i>Myeloid-Derived Suppressor Cells</i>	Células Supresoras de Origen Mieloide
ME	<i>Module Eigengene</i>	Eigengén del Módulo
miARN	<i>MicroARN</i>	-
MMP14	<i>Matrix Metalloproteinase 14</i>	Metaloproteínasa de matriz 14
NCoR	<i>Nuclear Receptor Co-Repressor</i>	Correpresor del Receptor Nuclear
NF- κ B	<i>Nuclear Factor Kappa-light-chain-enhancer of activated B cells</i>	Factor Nuclear Kappa de Células B Activadas
NK	<i>Natural Killer</i>	Células Asesinas Naturales
ORA	<i>Over-Representation Analysis</i>	Análisis de Sobrerepresentación
padj	<i>Adjusted p-value</i>	p-valor Ajustado
PanIN	<i>Pancreatic Intraepithelial Neoplasia</i>	Neoplasia Intraepitelial Pancreática
PCA	<i>Principal Component Analysis</i>	Análisis de Componentes Principales
PDAC	<i>Pancreatic Ductal Adenocarcinoma</i>	Adenocarcinoma Ductal Pancreático
PI3K-AKT	<i>Phosphoinositide 3-Kinase / Protein Kinase B</i>	Fosfoinositol 3-Quinasa / Proteína Quinasa B
PPI	<i>Protein-Protein Interaction</i>	Interacción Proteína-Proteína
qRT-PCR	<i>Quantitative Reverse Transcription PCR</i>	PCR Cuantitativa con Transcripción Inversa

R ²	<i>Coefficient of Determination</i>	Coeficiente de Determinación
RNA-seq	<i>RNA Sequencing</i>	Secuenciación Masiva de ARN
STAR	<i>Spliced Transcripts Alignment to a Reference</i>	Alineamiento de Transcritos Procesados a una Referencia
STING1	<i>Stimulator of Interferon Genes 1</i>	Estimulador de Genes de Interferón 1
sva	<i>Surrogate Variable Analysis</i>	Análisis de Variables Sustitutas
TAMs	<i>Tumor-Associated Macrophages</i>	Macrófagos Asociados al Tumor
TCGA	<i>The Cancer Genome Atlas</i>	Atlas del Genoma del Cáncer
TCGA-PAAD	<i>TCGA - Pancreatic Adenocarcinoma</i>	TCGA - Adenocarcinoma Pancreático
TGF-β	<i>Transforming Growth Factor Beta</i>	Factor de Crecimiento Transformante Beta
TICAM1	<i>Toll-like Receptor Adaptor Molecule 1</i>	Molécula adaptadora 1 de receptores tipo Toll
TME	<i>Tumor Microenvironment</i>	Microambiente Tumoral
TNFAIP3	<i>Tumor Necrosis Factor Alpha-Induced Protein 3</i>	Proteína 3 inducida por el factor de necrosis tumoral alfa
TOM	<i>Topological Overlap Matrix</i>	Matriz de Solapamiento Topológico
Tregs	<i>Regulatory T Cells</i>	Células T Reguladoras
UCSC Xena	<i>University of California Santa Cruz Xena</i>	Plataforma de Datos Genómicos de la Universidad de California Santa Cruz
VST	<i>Variance Stabilizing Transformation</i>	Transformación de Estabilización de la Varianza
WGCNA	<i>Weighted Gene Co-expression Network Analysis</i>	Análisis de Redes de Coexpresión Génica Ponderada
XGBoost	<i>Extreme Gradient Boosting</i>	Potenciación Extrema del Gradiente

ÍNDICE DE TABLAS & FIGURAS

1. **Tabla 0.** Lista de abreviaturas. 3
2. **Figura 1.** Pipeline bioinformático para el análisis de adenocarcinoma ductal pancreático (PDAC). El flujo de trabajo se describe en detalle en las secciones 3.1 a 3.9. 11
3. **Figura 2.** Diagramas de caja de la distribución de expresión por muestra antes y después de la normalización VST. 17
4. **Figura 3.** Análisis de componentes principales (PCA) antes y después de la corrección batch con ComBat. Las muestras se colorean según su condición (tumor/normal) y forma según la fuente de datos (TCGA/GTEX). 18
5. **Figura 4.** Heatmap de correlación entre muestras tras la normalización VST y corrección batch. 19

6. **Figura 5.** Volcano plot del análisis de expresión diferencial. Rojo: genes sobreexpresados ($\log_2FC > 1$, $p_{adj} < 0,05$). Azul: genes infraexpresados ($\log_2FC < -1$, $p_{adj} < 0,05$). Gris: genes no significativos. 19
7. **Figura 6.** Heatmap de los 50 genes más diferencialmente expresados (top 25 UP y top 25 DOWN por $|\log_2FC|$). Las columnas representan muestras y las filas genes. 20
8. **Figura 7.** Dendrograma de agrupamiento jerárquico de las muestras tumorales para detección de outliers. La línea roja indica el umbral de corte. 21
9. **Figura 8.** Selección del soft threshold (beta). Izquierda: ajuste al modelo libre de escala (R^2) en función de la potencia. Derecha: conectividad media en función de la potencia. 22
10. **Figura 9.** Dendrograma de genes con asignación de módulos de expresión. Cada color representa un módulo diferente. 23
11. **Figura 10.** Heatmap de correlación módulo-rasgo clínico. Cada celda contiene el coeficiente de correlación de Pearson (r) y el p-valor. Los módulos ME6/red ($r = -0,251$) y ME4/yellow ($r = 0,240$) muestran las correlaciones más relevantes con la variable mortalidad. 24
12. **Figura 11.** Diagrama de filtrado del pipeline de selección de genes. Se muestra la reducción progresiva desde 39385 genes iniciales hasta 331 genes hub. 25
13. **Figura 12.** Relación entre Module Membership (kME) y Gene Significance para mortalidad en los módulos ME6/red (izquierda) y ME4/yellow (derecha). 25
14. **Figura 13.** Heatmap de expresión de los 50 genes clave con mayor Module Membership. Las filas representan genes y las columnas muestras tumorales. 26
15. **Tabla 1.** Validación del pipeline con genes conocidos de PDAC. 27
16. **Figura 14.** Forest plot de los hazard ratios (Cox univariante) para los 10 genes de mayor significación del módulo ME4/yellow (riesgo, $HR > 1$) y los 5 genes más significativos del módulo ME6/red (protector, $HR < 1$). Se muestran los intervalos de confianza del 95 %. La línea discontinua roja indica $HR = 1$ (sin efecto). 29
17. **Figura 15.** Curvas de Kaplan-Meier de los 3 genes más significativos de cada módulo. Fila superior: módulo ME4/yellow (MET, ARF6, ITGB6) (riesgo), donde la alta expresión se asocia con menor supervivencia. Fila inferior: módulo ME6/red (KATNAL2, NIPSNAP3B, MIR600HG) (protector), donde la alta expresión se asocia con mayor supervivencia. 29
18. **Tabla 2.** Firma genética pronóstica LASSO-Cox. Los genes se ordenan por valor absoluto del coeficiente. 30
19. **Figura 16.** Selección del parámetro de regularización α del modelo LASSO-Cox mediante validación cruzada. 31
20. **Figura 17.** Coeficientes LASSO de los 12 genes seleccionados en la firma pronóstica. 31
21. **Figura 18.** Curvas de Kaplan-Meier de los grupos de alto y bajo riesgo definidos por la

firma LASSO-Cox de 12 genes. Log-rank $p = 0,030$.

32

22. **Figura 19.** Distribución del risk score LASSO-Cox en los pacientes de TCGA-PAAD, coloreados según su estado vital. 33

23. **Tabla A1.** Resultados del análisis de regresión de Cox univariante para los 154 genes clave con significación estadística tras corrección FDR (Benjamini-Hochberg). Se muestran el hazard ratio (HR), el intervalo de confianza al 95 %, el p-valor, la concordancia, la dirección del efecto y el valor de FDR. Los genes se ordenan por p-valor. 49

RESUMEN

El adenocarcinoma ductal pancreático (PDAC) es uno de los cánceres con peor pronóstico, con una supervivencia a 5 años inferior al 12 %. La mayoría de los pacientes se diagnostican en estadios avanzados debido a la ausencia de síntomas tempranos y de biomarcadores clínicos fiables, lo que limita las opciones terapéuticas disponibles.

En este trabajo se propone un análisis bioinformático basado en datos públicos de RNA-seq para identificar genes candidatos a biomarcadores pronósticos en PDAC. Se integran datos de expresión génica de muestras tumorales procedentes de TCGA-PAAD ($n = 183$) y de tejido pancreático normal de GTEx ($n = 167$), aplicando análisis diferencial (DESeq2), redes de coexpresión génica (WGCNA) y enriquecimiento funcional para identificar genes hub clínicamente relevantes. A partir de la intersección de genes diferencialmente expresados y genes hub correlacionados con mortalidad, se construye una firma génica pronóstica mediante regresión LASSO-Cox, obteniendo un modelo de doce genes capaz de estratificar a los pacientes en grupos de alto y bajo riesgo de mortalidad.

ABSTRACT

Pancreatic ductal adenocarcinoma (PDAC) is one of the cancers with the worst prognosis, with a 5-year survival rate below 12%. Most patients are diagnosed at advanced stages due to the lack of early symptoms and reliable clinical biomarkers, which limits the available therapeutic options.

This study proposes a bioinformatics analysis based on public RNA-seq data to identify candidate prognostic biomarker genes in PDAC. Gene expression data from tumour samples obtained from TCGA-PAAD ($n = 183$) and normal pancreatic tissue from GTEx ($n = 167$) are integrated, applying differential expression analysis (DESeq2), gene co-expression networks (WGCNA) and functional enrichment to identify clinically relevant hub genes. From the

intersection of differentially expressed genes and hub genes correlated with mortality, a prognostic gene signature is built using LASSO-Cox regression, yielding a twelve-gene model capable of stratifying patients into high- and low-risk mortality groups.

Keywords: pancreatic ductal adenocarcinoma (PDAC); RNA-seq; differential expression; WGCNA; survival analysis; LASSO-Cox; prognostic biomarker.

1. Introducción

1.1. Contexto y justificación

El adenocarcinoma ductal pancreático (PDAC, por sus siglas en inglés, Pancreatic Ductal Adenocarcinoma) es una de las neoplasias más agresivas del tracto gastrointestinal y representa aproximadamente el 85–90 % de todos los tumores pancreáticos. Según los datos de GLOBOCAN 2022, se diagnostican alrededor de 510 000 nuevos casos anuales a nivel mundial, lo que sitúa al cáncer de páncreas como el duodécimo tipo de cáncer más frecuente (1,2).

La supervivencia global a 5 años del PDAC se sitúa en torno al 12 %, y aunque ha mejorado ligeramente en las últimas décadas, sigue siendo una de las más bajas entre los tumores sólidos. Esto se debe en gran parte a que más del 52 % de los pacientes se diagnostican en estadio avanzado, cuando el tumor ya se ha extendido a órganos distantes y la supervivencia a 5 años cae por debajo del 3 % (2).

Rahib et al. estimaron que para el año 2030, en Estados Unidos, el cáncer de páncreas podría convertirse en la segunda causa principal de muerte por cáncer, superando al cáncer de mama y colorrectal (3). Proyecciones globales posteriores apuntan también a incrementos sostenidos de la incidencia en las próximas décadas, en parte debido a factores de riesgo como el tabaquismo, la obesidad, la diabetes mellitus tipo 2, la pancreatitis crónica y la historia familiar (4).

En este contexto, la identificación de biomarcadores moleculares basados en perfiles de expresión génica representa una aproximación prometedora para mejorar el diagnóstico temprano y la estratificación pronóstica de los pacientes con PDAC.

1.2. Biología molecular del PDAC

El PDAC está caracterizado por cuatro alteraciones genéticas principales conocidas como los “*Big Four*” (64): KRAS (*Kirsten Rat Sarcoma Viral Oncogene Homolog*), TP53 (*Tumor Protein*

P53), *CDKN2A* (*Cyclin Dependent Kinase Inhibitor 2A*) y *SMAD4* (*SMAD Family Member 4*) (1,5).

KRAS es el oncogén más frecuentemente mutado en PDAC, con mutaciones activadoras presentes en más del 90 % de los casos, sobre todo en los codones 12, 13 y 61. Las variantes más comunes (G12D, G12V, G12R) provocan la activación constitutiva de las vías *MAPK* (*Mitogen-Activated Protein Kinase*) y *PI3K-AKT* (*Phosphoinositide 3-Kinase/Protein Kinase B*), dos rutas de señalización intracelular que regulan la proliferación, la supervivencia y el metabolismo celular, promoviendo así el crecimiento tumoral descontrolado (5,6,7).

TP53 actúa como supresor tumoral y se encuentra mutado en el 50–90 % de los PDAC. La proteína *p53* tiene un papel clave en la limitación del desarrollo de lesiones precursoras (*PanIN*, por sus siglas en inglés, *Pancreatic Intraepithelial Neoplasia*) hacia carcinoma invasivo, y sus mutaciones se asocian con inestabilidad genómica y resistencia a la apoptosis (5,8).

CDKN2A codifica las proteínas *p16* y *p19*, que regulan el punto de control G1/S del ciclo celular inhibiendo las quinasas *CDK4/6* (*Cyclin Dependent Kinase 4/6*). Su inactivación, presente en el 50–98 % de los casos, se produce por delección homocigota, mutación intragénica o silenciamiento epigenético por hipermetilación del promotor (5).

SMAD4 (también conocido como *DPC4*, *Deleted in Pancreatic Cancer 4*) participa en la vía de señalización *TGF-β/SMAD* (*Transforming Growth Factor Beta*), que tiene un papel dual en la tumorigénesis: actúa como supresor tumoral en estadios tempranos y como promotor de invasión y metástasis en estadios avanzados. La pérdida de *SMAD4* se observa en aproximadamente el 55 % de los PDAC y se asocia con un patrón de enfermedad metastásica generalizada (5,6).

Además de estas alteraciones mutacionales, el PDAC se caracteriza por la sobreexpresión de diversos genes que no se alteran por mutación sino por una desregulación en su nivel de transcripción. Entre ellos destacan las mucinas *MUC1* y *MUC4*, glicoproteínas de membrana que en tejido pancreático normal tienen una expresión baja o ausente pero que en PDAC se sobreexpresan de forma marcada, contribuyendo a la invasión tumoral, la evasión del sistema inmunitario y la resistencia a la apoptosis (5, 6). La mesotelina (*MSLN*, por sus siglas en inglés *Mesothelin*) es otra proteína de superficie sobreexpresada en la mayoría de los PDAC, implicada en la adhesión celular y la diseminación peritoneal, y que se ha propuesto como diana terapéutica y marcador sérico complementario al *CA19-9* (6). *CEACAM6* (*Carcinoembryonic Antigen Related Cell Adhesion Molecule 6*), prácticamente indetectable en

páncreas sano, presenta una sobreexpresión intensa en PDAC y se asocia con la inhibición de la anoikis y la promoción de la invasión celular (5). S100A4, miembro de la familia de proteínas de unión a calcio S100, se sobreexpresa en el estroma tumoral del PDAC y participa en la transición epitelio-mesénquima, la remodelación de la matriz extracelular y la metástasis (6). Por último, la citoqueratina 19 (KRT19) es uno de los marcadores de sobreexpresión más consistentes en PDAC y se utiliza como marcador de células epiteliales tumorales en estudios de expresión génica (5).

A diferencia de los *Big Four*, cuyas alteraciones se producen a nivel de la secuencia del DNA (mutaciones, deleciones o silenciamiento epigenético), estos genes descritos anteriormente se alteran a nivel transcripcional (5,6), lo que los hace detectables mediante análisis de expresión génica como el planteado en este trabajo. Esta distinción es relevante porque un pipeline basado en datos de RNA-seq detectará con mayor facilidad genes con cambios en la expresión del mRNA que genes cuya alteración es mutacional sin cambio significativo en el nivel de transcripción.

Una característica distintiva del PDAC es su microambiente tumoral (TME, por sus siglas en inglés, *Tumor Microenvironment*), dominado por una reacción desmoplásica intensa en la que el estroma puede llegar a constituir hasta el 80 % de la masa tumoral (8). Este estroma denso está compuesto principalmente por fibroblastos asociados al cáncer (CAFs), matriz extracelular, células inmunitarias y vasos sanguíneos. La desmoplasia no es simplemente una barrera física, sino que participa activamente en la progresión tumoral: dificulta la llegada de fármacos al tumor, contribuye a la inmunosupresión local y favorece la invasión y la metástasis (9). Esta complejidad del microambiente hace que el estudio del PDAC requiera enfoques que analicen no sólo genes individuales, sino patrones de coexpresión a nivel de red.

1.3. Biomarcadores en cáncer de páncreas

Un biomarcador se define como una característica biológica medible objetivamente que sirve como indicador de procesos biológicos normales, patológicos o de respuesta a una intervención terapéutica (10).

En el contexto del PDAC, el antígeno carbohidrato 19-9 (CA19-9) constituye el único biomarcador sérico aprobado por la FDA para el manejo clínico del cáncer de páncreas (11). El CA19-9 presenta una sensibilidad del 79–81 % y una especificidad del 82–90 % en pacientes sintomáticos. Sin embargo, tiene limitaciones importantes: no se expresa en el 5–10 % de la población, concretamente en individuos que carecen del antígeno Lewis, una enzima

fucosiltransferasa necesaria para la síntesis del epítipo sialil-Lewis a que reconoce el anticuerpo del ensayo. Además, el CA19-9 puede estar elevado en patologías benignas como la pancreatitis o la obstrucción biliar, y su utilidad para el cribado poblacional es limitada por su bajo valor predictivo positivo en poblaciones de baja prevalencia (11,12).

Adicionalmente, el antígeno carcinoembrionario (CEA) se utiliza de manera complementaria, aunque su sensibilidad y especificidad son inferiores a las del CA19-9 (12). Estas limitaciones ponen de manifiesto la necesidad de desarrollar nuevos biomarcadores moleculares basados en perfiles de expresión génica.

En los últimos años, los avances en tecnologías de secuenciación masiva como RNA-seq (RNA sequencing) han permitido estudiar la expresión de miles de genes de forma simultánea, lo que ha abierto la puerta a la identificación de biomarcadores basados en firmas génicas. Dentro de este enfoque, resultan especialmente interesantes los llamados genes hub, que son genes que ocupan posiciones centrales dentro de redes de coexpresión génica. La idea es que, al estar muy conectados con otros genes de su módulo funcional, es más probable que su alteración tenga consecuencias biológicas relevantes para la enfermedad (13).

1.4. Estado del arte

En los últimos años varios grupos han trabajado en la identificación de biomarcadores en PDAC mediante análisis de expresión génica y redes de coexpresión. Pero antes de entrar en los trabajos específicos de páncreas, conviene mencionar que la combinación de WGCNA con análisis diferencial y supervivencia se ha consolidado como estrategia válida en oncología en general, con aplicaciones en múltiples tumores.

Por ejemplo, en cáncer gástrico, Zhang et al. (2021) aplicaron WGCNA sobre datos de TCGA y GEO para identificar módulos de expresión asociados a pronóstico e infiltración inmune, construyendo un modelo de 5 genes validado en cohortes independientes mediante regresión LASSO-Cox (14). En cáncer de cérvix, Chen et al. (2021) combinaron WGCNA con regresión LASSO-Cox sobre datos de TCGA y GTEx para establecer un modelo pronóstico de 6 genes (15). Más recientemente, Hu et al. (2025) aplicaron DESeq2 junto con WGCNA y algoritmos de machine learning como XGBoost, LASSO y Random Forest en cáncer de tiroides, identificando cuatro biomarcadores clave con AUC > 0,95 (16). Estos trabajos en otros tipos de cáncer apoyan la robustez del pipeline metodológico empleado en este TFM y demuestran que es reproducible en distintos contextos tumorales.

En cuanto a los trabajos específicos en PDAC, Giulietti et al. (2016) fueron de los primeros en aplicar WGCNA con datos de microarrays de 36 muestras tumorales y 16 controles, identificando genes hub implicados en rutas oncogénicas relevantes (17). Liu et al. (2019) y Lu et al. (2019) también trabajaron con microarrays de GEO incorporando redes PPI, identificando genes del ciclo celular y de remodelación de matriz extracelular como CDK1, COL1A1 o MMP14, aunque sin integrar análisis de supervivencia (60, 61). Algo más completo fue el enfoque de Nisar et al. (2021), que combinaron múltiples datasets con WGCNA y análisis diferencial correlacionando módulos con supervivencia, aunque mezclando microarrays y RNA-seq (18). Ren et al. (2021) añadieron validación experimental mediante qRT-PCR e inmunohistoquímica, reforzando la solidez de sus hallazgos (19). Wu et al. (2021) demostraron el potencial exploratorio de estas aproximaciones descubriendo DDX60L como nuevo oncogén en PDAC (20), mientras que Mantini et al. (2024) dirigieron el foco al microambiente tumoral estromal (21). El trabajo más reciente de Salihoglu et al. (2025) incorporó machine learning y redes génicas para mejorar la estratificación de pacientes (63).

En conjunto, aunque existe una base sólida de estudios bioinformáticos en PDAC, la mayoría se apoya en datos de microarrays, trabaja con cohortes pequeñas o no integra de forma sistemática análisis de expresión diferencial, redes de coexpresión y modelos de supervivencia dentro de un mismo pipeline. Este trabajo combina estas aproximaciones dentro de un mismo pipeline sobre datos de RNA-seq, que ofrece ventajas frente a los microarrays como un rango dinámico más amplio, mayor sensibilidad para detectar transcritos de baja abundancia y la capacidad de identificar variantes de splicing sin necesidad de sondas prediseñadas (22).

2. Hipótesis y objetivos

2.1. Hipótesis

Los genes con expresión significativamente alterada en tejido tumoral pancreático respecto al tejido normal presentan patrones de expresión que permiten identificar biomarcadores con valor pronóstico en PDAC. Se espera que los genes hub identificados mediante la integración de expresión diferencial y redes de coexpresión muestren una asociación estadísticamente significativa con la supervivencia global de los pacientes.

2.2. Objetivo general

Identificar genes candidatos a biomarcadores pronósticos en adenocarcinoma pancreático mediante el análisis integrado de expresión diferencial y redes de coexpresión génica, y evaluar

su relevancia clínica mediante el desarrollo de una firma genética de supervivencia basada en regresión LASSO-Cox.

3. Materiales y métodos




Figura 1. Pipeline bioinformático para el análisis de adenocarcinoma ductal pancreático (PDAC). El flujo de trabajo se describe en detalle en las secciones 3.1 a 3.9.

3.1. Fuentes de datos y tecnología de secuenciación

Este trabajo utiliza datos de secuenciación masiva de RNA(RNA-seq), la tecnología de referencia actual para el análisis de perfiles de expresión génica (22).

Se descargaron datos de RNA-seq en forma de matrices de conteos crudos (raw counts) generados por el pipeline STAR (23) de dos fuentes públicas:

Para las muestras tumorales, se obtuvieron los datos del proyecto TCGA-PAAD a través del portal GDC (Genomic Data Commons) utilizando el paquete de R TCGAbiolinks v2.28.4 (24,25). Se seleccionaron los datos de tipo «STAR - Counts» (unstranded), correspondientes a conteos de lectura sin normalizar alineados con el genoma de referencia. Este dataset comprende 183 muestras de adenocarcinoma ductal pancreático con anotación clínica asociada (edad, sexo, estadio tumoral, tiempo de supervivencia y estado vital). Los identificadores de genes se proporcionaron en formato ENSEMBL con número de versión (por ejemplo, ENSG00000133703.13).

Para las muestras de tejido normal, se descargaron los datos del proyecto GTEx v8 correspondientes a páncreas normal a través de la plataforma UCSC Xena (77). GTEx (Genotype-Tissue Expression Project) proporciona datos de expresión génica de tejidos normales procedentes de donantes sanos (26). Los datos de ambas fuentes son comparables gracias a que UCSC Xena proporciona tanto los datos de TCGA como los de GTEx reprocesados con el pipeline Toil-STAR con parámetros por defecto (77), lo que garantiza un alineamiento y cuantificación uniformes. Se obtuvieron 167 muestras de páncreas normal, también en formato de conteos esperados (expected counts) con identificadores ENSEMBL.

3.2. Preprocesamiento e integración de datos

La integración de las dos fuentes de datos requirió varios pasos de preprocesamiento. En primer lugar, se eliminaron los sufijos de versión de los identificadores ENSEMBL (todo lo posterior al punto decimal) para unificar la nomenclatura entre TCGA y GTEx. Cuando existían múltiples versiones para un mismo gen, los conteos se sumaron mediante agregación.

A continuación se aplicó un filtrado por baja expresión para eliminar genes no informativos. Se retuvieron únicamente los genes que cumplieran dos criterios simultáneamente: (i) suma total de conteos ≥ 10 a lo largo de todas las muestras, y (ii) expresión > 0 en al menos el 10 % de las

muestras (≥ 35 muestras). Tras este filtrado, la matriz se redujo de 56 600 a 39 385 genes en 350 muestras (183 tumorales + 167 normales).

Para corregir los efectos batch derivados de combinar los datasets de TCGA y GTEx, se aplicó el método ComBat del paquete sva de R (59). Los datos se transformaron previamente a $\log_2(\text{counts} + 1)$ y se utilizó un modelo paramétrico (`par.prior = TRUE`) con `mod = NULL`, ya que la variable de grupo (tumor vs. normal) está completamente confundida con el batch. La eficacia de la corrección se verificó mediante PCA (Figura 2).

Finalmente, se realizó una transformación de estabilización de la varianza (Variance Stabilizing Transformation, VST) mediante la función `vst()` del paquete DESeq2, con el parámetro `blind = FALSE` para que la transformación tuviera en cuenta el diseño experimental. La matriz VST resultante se utilizó como entrada para los análisis que lo requirieron.

3.3. Análisis de expresión diferencial con DESeq2

El análisis de expresión diferencial se realizó con DESeq2 v1.40.2 en R v4.3.0 (28). Se comparó el grupo tumor ($n = 183$, TCGA-PAAD) frente al grupo normal ($n = 167$, GTEx). Se creó un objeto `DESeqDataSet` con la fórmula de diseño `~ grupo` y se ejecutó la función `DESeq()` con los parámetros por defecto (distribución binomial negativa, normalización por mediana de ratios, estimación de dispersión empírica bayesiana y test de Wald para la significación estadística).

Los resultados se ajustaron para comparaciones múltiples mediante el método de Benjamini-Hochberg (29).

Se consideraron genes diferencialmente expresados (DEGs) aquellos que cumplieran simultáneamente: $p\text{-valor ajustado (padj)} < 0,05$ y $|\log_2\text{FoldChange}| > 1$ (al menos 2 veces de cambio en cualquier dirección). Los genes con `padj = NA` fueron excluidos del análisis.

3.4. Análisis de redes de coexpresión génica (WGCNA)

Para la construcción de la red de coexpresión se empleó el paquete WGCNA en R. El análisis se llevó a cabo únicamente con las muestras tumorales de TCGA ($n = 183$), ya que interesa identificar patrones de coexpresión propios del tumor.

Como input para WGCNA se partió de los DEGs que cumplieran criterios estrictos ($p\text{-valor ajustado} < 0,01$ y $|\log_2\text{FC}| > 2$). Sobre este conjunto se aplicó un filtrado adicional basado en la variabilidad de expresión, utilizando la MAD (Median Absolute Deviation, por sus siglas en inglés) y reteniendo únicamente los genes con MAD por encima del percentil 75. Se optó por la

MAD en lugar de la desviación estándar porque es una medida más robusta frente a valores extremos. El objetivo de este filtrado fue quedarse solo con los genes que muestran mayor variación entre muestras, ya que WGCNA funciona mejor con conjuntos reducidos de genes con alta variabilidad biológica; incluir genes con poca variación añade ruido a la red y dificulta la detección de módulos reales de coexpresión (13). Tras aplicar estos filtros se obtuvieron 6 561 genes.

Se aplicó la función *goodSamplesGenes()* para descartar genes y muestras con exceso de valores faltantes. Además, se eliminaron muestras outlier mediante el criterio $Q3 + 1,5 \times IQR$ aplicado sobre la distancia del dendrograma de clustering jerárquico.

Para la elección del umbral de potencia (soft threshold), se evaluaron potencias de 1 a 10 (valores enteros) y de 12 a 20 (valores pares), seleccionando aquella que alcanza un ajuste al modelo libre de escala ($R^2 > 0,85$) con conectividad media razonable. La red se construyó con la función *blockwiseModules()* con los parámetros: tipo de red signed, tamaño mínimo de módulo 30 genes, y altura de corte para fusión de módulos similares de 0,25.

Los hub genes se definieron como aquellos con un valor absoluto de kME (module membership) superior a 0,5 y un valor absoluto de GS (gene significance, correlación con mortalidad) superior a 0,15. La intersección de estos hub genes con los DEGs significativos (p -valor ajustado $< 0,05$ y $|\log_2FC| > 1$) dio como resultado los genes clave candidatos para los análisis posteriores.

3.5. Integración y selección de genes clave

Los genes hub se definieron como aquellos con Module Membership (kME) $> 0,5$ y $|\text{Gene Significance para mortalidad}| (|GS_death|) > 0,15$ dentro de los módulos significativamente correlacionados con el rasgo de mortalidad (13, 30). Los genes candidatos finales se obtuvieron como la intersección entre el conjunto de DEGs (p -valor ajustado $< 0,05$ y $|\log_2FC| > 1$) y los genes hub identificados en WGCNA ($\text{DEG} \cap \text{Hub}$). Esta estrategia de doble filtro, empleada previamente en estudios similares de WGCNA aplicados a cáncer (14, 15, 18), busca genes que no solo muestren expresión diferencial significativa entre tumor y tejido normal, sino que además ocupen posiciones centrales en módulos de coexpresión clínicamente relevantes.

3.6. Validación con genes conocidos de PDAC

Como control de calidad del pipeline, se verificó la presencia en los resultados de genes previamente implicados en PDAC: KRAS, TP53, CDKN2A, SMAD4, MUC1, MUC4, S100A4,

CEACAM6 y MSLN, junto con KRT19, VIM, S100P y CEACAM5 (1, 5, 6). La detección de estos 13 genes conocidos en las distintas etapas del análisis sirve como indicador de la sensibilidad y coherencia biológica del enfoque.

3.7. Análisis de supervivencia

Se analizó la asociación de los genes clave con la supervivencia global utilizando los datos clínicos de los pacientes de TCGA-PAAD con información completa de seguimiento. Se emplearon los paquetes survival y survminer de R. Para las curvas de Kaplan-Meier, los pacientes se estratificaron en dos grupos (alta y baja expresión) utilizando la mediana de expresión como punto de corte. La significación se evaluó mediante el test de log-rank (p -valor $< 0,05$).

Para evaluar la asociación entre la expresión de cada gen clave y la supervivencia global, se empleó la regresión de Cox de riesgos proporcionales de forma univariante. Para cada gen, se calculó el Hazard Ratio (HR) con su intervalo de confianza al 95 %, utilizando la expresión normalizada (z-score) como variable continua. Un $HR > 1$ indica que una mayor expresión se asocia con mayor riesgo de muerte, mientras que un $HR < 1$ indica un efecto protector. Dado que se evaluaron todos los genes clave de los módulos seleccionados, se aplicó corrección por comparaciones múltiples de Benjamini-Hochberg y se consideraron significativos los genes con $FDR < 0,05$.

3.8. Modelo LASSO-Cox

Para construir un modelo pronóstico basado en un número reducido de genes, se aplicó una regresión de Cox con penalización LASSO (Least Absolute Shrinkage and Selection Operator, por sus siglas en inglés) (33). El modelo se implementó de forma manual en Python siguiendo la formulación de Tibshirani (33), mediante un algoritmo de descenso por coordenadas con penalización L1, lo que permitió adaptar el código al resto del pipeline sin añadir dependencias externas. El parámetro de regularización α se seleccionó mediante validación cruzada de 5 folds evaluando 10 valores candidatos. La firma resultante se evaluó mediante el C-index (concordance index, por sus siglas en inglés), con intervalos de confianza al 95 % estimados por bootstrap (1 000 repeticiones), y el test de log-rank para comparar las curvas de supervivencia entre los grupos de alto y bajo riesgo definidos por la mediana del risk score.

Todas las representaciones gráficas del trabajo se generaron en Python mediante Matplotlib (34) y seaborn (27), y en R mediante ggplot2 y los paquetes de visualización integrados en survminer y WGCNA.

3.9. Anotación funcional de la firma pronóstica

Para interpretar biológicamente los doce genes seleccionados por el modelo LASSO-Cox, se realizó una anotación funcional individual basada en revisión bibliográfica estructurada. Dado que un conjunto de doce genes no permite un análisis de enriquecimiento clásico (ORA) con potencia estadística suficiente para detectar sobre-representación significativa en términos GO o rutas KEGG, se optó por una aproximación cualitativa que describe las funciones conocidas de cada gen, sus procesos biológicos asociados, las rutas de señalización en las que participan y su relevancia en el contexto oncológico.

Las fuentes consultadas para la anotación incluyeron UniProt, GeneCards, The Human Protein Atlas, Ensembl (versión 113) y literatura primaria indexada en PubMed. Para cada gen se documentaron: la función molecular principal, los procesos biológicos en los que participa según la ontología GO (35) y las rutas de señalización relevantes según KEGG (36), así como la evidencia disponible sobre su implicación en cáncer, con especial atención al PDAC. Los identificadores ENSEMBL se convirtieron a símbolos HGNC (HUGO Gene Nomenclature Committee) mediante biomaRt cuando fue necesario. Esta aproximación permite contextualizar biológicamente la firma pronóstica y generar hipótesis sobre los mecanismos que subyacen a la estratificación de riesgo observada.

3.10. Scripts

Los scripts utilizados en este trabajo están disponibles en un repositorio público de GitHub: <https://github.com/inxstseq/TFM-PDAC-InesTorres-MAY26>

4. Resultados

En esta sección se presentan los resultados obtenidos en cada etapa del pipeline bioinformático, siguiendo el flujo descrito en la Figura 1. En primer lugar, se describen el preprocesamiento y la integración de los datos de TCGA-PAAD y GTEx (sección 4.1), seguidos del análisis de expresión diferencial (4.2). A continuación, se construye la red de coexpresión génica mediante WGCNA (4.3) y se integran los genes diferencialmente expresados con los

genes hub de los módulos clínicamente relevantes (4.4). Sobre el conjunto de genes clave resultante se realiza un análisis de supervivencia individual (4.5), seguido de la construcción de una firma pronóstica multigénica mediante regresión LASSO-Cox (4.6), y finalmente una anotación funcional (4.7) que proporciona contexto biológico a los genes clave.

4.1. Preprocesamiento e integración de datos

Tras la descarga y armonización de los datos de RNA-seq, la matriz combinada incluyó un total de 350 muestras (183 tumorales de TCGA-PAAD y 167 de tejido pancreático normal de GTEx). El filtrado por baja expresión (suma de conteos ≥ 10 y expresión > 0 en al menos el 10 % de las muestras) redujo el número de genes de la matriz original a 39 385 genes.

La normalización mediante VST y la corrección batch con ComBat se evaluaron visualmente. La Figura 2 muestra los diagramas de caja de la distribución de expresión por muestra antes y después de la normalización. Se observa que tras la VST, las distribuciones se homogenizan, eliminando las diferencias sistemáticas de escala entre muestras.




Figura 2. Diagramas de caja de la distribución de expresión por muestra antes y después de la normalización VST.

El análisis de componentes principales (PCA) antes y después de la corrección batch con ComBat se presenta en la Figura 3. Antes de la corrección, las muestras se agrupan principalmente por fuente de datos (TCGA vs. GTEx), lo que indicaba un efecto batch. Tras aplicar ComBat, la separación principal pasó a ser por condición biológica (tumor vs. normal), confirmando la eliminación efectiva del efecto batch técnico.




Figura 3. Análisis de componentes principales (PCA) antes y después de la corrección batch con ComBat. Las muestras se colorean según su condición (tumor/normal) y forma según la fuente de datos (TCGA/GTEx).

La Figura 4 muestra el heatmap de correlación entre muestras basado en los datos normalizados. Se distinguen claramente dos bloques principales correspondientes a las muestras tumorales y normales, lo que confirma que el preprocesamiento preservó la señal biológica.




Figura 4. Heatmap de correlación entre muestras tras la normalización VST y corrección batch.

4.2. Análisis de expresión diferencial

El análisis de expresión diferencial con DESeq2 identificó un total de 32 113 genes diferencialmente expresados ($p_{adj} < 0,05$ y $|\log_2FC| > 1$) entre las muestras tumorales y normales. De estos, 5 036 genes se encuentran sobreexpresados ($\log_2FC > 1$) y 27 077 infraexpresados ($\log_2FC < -1$) en el tejido tumoral respecto al normal.

La Figura 5 muestra el volcán plot del análisis diferencial. Cada punto representa un gen, con el $\log_2$ Fold Change en el eje X y el $-\log_{10}(adj)$ en el eje Y. Los genes significativos sobreexpresados aparecen en rojo y los infraexpresados en azul. Se destacan los genes con mayor cambio de expresión y mayor significación estadística.



Figura 5. Volcano plot del análisis de expresión diferencial. Rojo: genes sobreexpresados ($\log_2FC > 1$, $p_{adj} < 0,05$). Azul: genes infraexpresados ($\log_2FC < -1$, $p_{adj} < 0,05$). Gris: genes no significativos.

La Figura 6 presenta el heatmap de los 50 genes con mayor expresión diferencial (top 25 sobreexpresados y top 25 infraexpresados, ordenados por $|\log_2FC|$). Se observa una separación clara de los patrones de expresión entre muestras tumorales y normales.




Figura 6. Heatmap de los 50 genes más diferencialmente expresados (top 25 UP y top 25 DOWN por $|\log_2FC|$). Las columnas representan muestras y las filas genes.

4.3. Red de coexpresión génica (WGCNA)

La red de coexpresión se construyó utilizando únicamente las 183 muestras tumorales de TCGA-PAAD, seleccionando los DEGs con criterios estrictos ($p_{adj} < 0,01$, $|\log_2FC| > 2$) y reteniendo aquellos con mayor variabilidad entre pacientes ($MAD > \text{percentil } 75$). Antes de construir la red, se realizó un control de calidad para detectar muestras atípicas (outliers): se agruparon jerárquicamente todas las muestras en función de su similitud y se estableció un umbral de corte (altura = 115). Las muestras que superaban dicho umbral, por ser demasiado diferentes al resto, fueron eliminadas del análisis, reduciéndose el número de muestras de 183 a 165. La Figura 7 muestra el dendrograma resultante, donde la línea roja punteada indica el umbral de exclusión aplicado.




Figura 7. Dendrograma de agrupamiento jerárquico de las muestras tumorales para detección de outliers. La línea roja indica el umbral de corte.

Para la construcción de la red se probaron distintos valores del parámetro beta (de 1 a 20) y se seleccionó $\beta = 7$, que fue el valor más pequeño que alcanzó un ajuste al modelo libre de escala con $R^2 \geq 0,80$, con una conectividad media de 117, minimizando al mismo tiempo la pérdida de conectividad (Figura 8).




Figura 8. Selección del soft threshold (beta). Izquierda: ajuste al modelo libre de escala (R^2) en función de la potencia. Derecha: conectividad media en función de la potencia.

El agrupamiento jerárquico sobre la distancia topológica (1-TOM) con la función *blockwiseModules()* identificó 18 módulos de coexpresión (Figura 9). Cada módulo agrupa genes con patrones de expresión similares y se identifica con un color. El módulo más grande fue el turquoise con 876 genes, seguido del blue con 612, el brown con 499 y el yellow con 474. Los módulos más pequeños fueron lightgreen (46 genes) y grey60 (54 genes). El módulo grey (1134 genes) contiene genes no asignados a ningún módulo.




Figura 9. Dendrograma de genes con asignación de módulos de expresión. Cada color representa un módulo diferente.

El análisis de correlación entre los Module Eigengenes y las variables clínicas se muestra en la Figura 10. Cada fila corresponde a un módulo (ME0–ME18; ME0 corresponde al módulo gris, que agrupa los genes no asignables a ningún módulo de coexpresión y que por convención no se considera biológicamente informativo, por lo que el análisis se centra en los 18 módulos restantes) y cada columna a una variable clínica (edad, sexo, estadio, supervivencia y mortalidad). En la columna de mortalidad, el módulo ME6/red muestra una correlación negativa ($r = -0,251$), mientras que el módulo ME4/yellow muestra una correlación positiva ($r = 0,240$). Estos dos módulos presentaron las correlaciones más relevantes con la variable mortalidad (31, 65).




Figura 10. Heatmap de correlación módulo-rasgo clínico. Cada celda contiene el coeficiente de correlación de Pearson (r) y el p-valor. Los módulos ME6/red ($r = -0,251$) y ME4/yellow ($r = 0,240$) muestran las correlaciones más relevantes con la variable mortalidad.

Una vez identificados los módulos de coexpresión con mayor correlación con mortalidad (ME6/red, $r = -0,251$; y ME4/yellow, $r = 0,240$), el siguiente paso consistió en cruzar los genes hub de estos módulos con los DEGs obtenidos en la sección 4.2, con el fin de retener únicamente aquellos genes que combinan relevancia clínica con expresión diferencial significativa.

4.4. Integración DEGs y genes hub

Se identificaron un total de 331 genes hub dentro de los módulos ME6/red (172 genes) y ME4/yellow (159 genes), definidos por los criterios de $kME > 0,5$ y $|GS_death| > 0,15$. Dado que la red WGCNA se construyó exclusivamente a partir de DEGs estrictos ($padj < 0,01$ y $|\log_2FC| > 2$), la totalidad de los 331 genes hub cumple también el criterio de expresión diferencial. La Figura 11 muestra el pipeline completo de filtrado, desde los 39 385 genes iniciales hasta los 331 genes hub.




Figura 11. Diagrama de filtrado del pipeline de selección de genes. Se muestra la reducción progresiva desde 39385 genes iniciales hasta 331 genes hub.

La Figura 12 representa, para cada gen de los módulos ME6/red y ME4/yellow, su Module Membership (kME, eje X) frente a su Gene Significance para mortalidad (GS_death, eje Y). Los genes con kME alto y |GS| alto (marcados en color) son aquellos que están bien conectados dentro de su módulo y cuya expresión se asocia con la mortalidad, lo que los convierte en los mejores candidatos a biomarcadores.




Figura 12. Relación entre Module Membership (kME) y Gene Significance para mortalidad en los módulos ME6/red (izquierda) y ME4/yellow (derecha).

La Figura 13 muestra un heatmap con los 50 genes clave que tienen mayor kME. Para cada gen se representan tres valores: su kME (lo conectado que está dentro de su módulo), su GS para mortalidad (lo relacionado que está con la muerte del paciente) y su log2FC (cuánto cambia su expresión entre tumor y normal). La barra de color del lateral indica a qué módulo pertenece cada gen: rojo para ME6 y amarillo para ME4. Los genes están ordenados de arriba abajo según su |kME|, así que los más centrales en la red aparecen primero.




Figura 13. Heatmap de expresión de los 50 genes clave con mayor Module Membership. Las filas representan genes y las columnas muestras tumorales.

Como control de calidad del pipeline, se evaluó la presencia de 13 genes previamente implicados en PDAC a lo largo de las distintas etapas del análisis (Tabla 1). De los cuatro

genes con alteraciones predominantemente mutacionales (KRAS, TP53, CDKN2A y SMAD4), solo KRAS y TP53 fueron detectados como DEGs; ninguno de ellos superó el filtrado por variabilidad de expresión necesario para entrar en la red WGCNA. Los nueve marcadores de sobreexpresión transcripcional (MUC1, MUC4, S100A4, CEACAM6, MSLN, KRT19, VIM, S100P y CEACAM5) fueron identificados como DEGs y asignados a módulos WGCNA. De estos, únicamente KRT19 cumplió ambos criterios para ser clasificado como gen hub ($kME = 0,835$; $|GS_death| = 0,194$) y, tras la intersección con los DEGs, como gen clave. Los demás marcadores transcripcionales presentaron valores de kME superiores a 0,5 en la mayoría de los casos, pero no alcanzaron el umbral de $|GS_death| > 0,15$ requerido para la clasificación como hub.

Tabla 1. Validación del pipeline con genes conocidos de PDAC.

Gen	log2FC	padj	DEG	WGCNA	Módulo	Hub	Gen Clave
KRAS	1,29	7,41e-105	✓	✗	-	✗	✗
TP53	1,15	1,64e-59	✓	✗	-	✗	✗
CDKN2A	0,92	2,08e-07	✗	✗	-	✗	✗
SMAD4	0,96	6,79e-54	✗	✗	-	✗	✗
MUC1	4,65	0,00e+00	✓	✓	yellow	✗	✗
MUC4	2,71	1,30e-61	✓	✓	yellow	✗	✗
S100A4	3,71	1,50e-172	✓	✓	brown	✗	✗
CEACAM6	6,2	0,00e+00	✓	✓	magenta	✗	✗
MSLN	5,63	4,09e-209	✓	✓	yellow	✗	✗
KRT19	6,26	0,00e+00	✓	✓	yellow	✓	✓
VIM	4,16	0,00e+00	✓	✓	black	✗	✗
S100P	5,47	5,39e-196	✓	✓	yellow	✗	✗
CEACAM5	7,28	2,27e-246	✓	✓	magenta	✗	✗

4.5. Análisis de supervivencia

El análisis de supervivencia se realizó sobre las 182 muestras tumorales con información completa de seguimiento (de las 183 originales, se excluyó una sin tiempo de supervivencia registrado), evaluando los 225 genes clave con nombre conocido de los módulos ME4/yellow y ME6/red. Tras aplicar corrección por comparaciones múltiples (Benjamini-Hochberg), 154 genes mantuvieron una asociación significativa con la supervivencia global (FDR < 0,05): 127 del módulo ME4/yellow y 27 del módulo ME6/red. Los genes con mayor significación fueron MET (FDR = $1,52 \times 10^{-5}$), ARF6 (FDR = $1,39 \times 10^{-4}$) e ITGB6 (FDR = $1,39 \times 10^{-4}$), todos del módulo ME4/yellow.

La Figura 14 muestra el forest plot con los 10 genes de menor FDR del módulo ME4/yellow y los 5 de menor FDR del módulo ME6/red. Los genes del módulo yellow presentaron HR > 1, indicando que una mayor expresión se asocia con peor pronóstico, mientras que los genes del módulo red mostraron HR < 1, lo que indica un efecto protector.




Figura 14. Forest plot de los hazard ratios (Cox univariante) para los 10 genes de mayor significación del módulo ME4/yellow (riesgo, HR > 1) y los 5 genes más significativos del módulo ME6/red (protector, HR < 1). Se muestran los intervalos de confianza del 95 %. La línea discontinua roja indica HR = 1 (sin efecto).

A modo de representación visual del comportamiento opuesto de ambos módulos, la Figura 15 muestra las curvas de Kaplan-Meier de los 3 genes con menor FDR de cada módulo. En los genes del módulo ME4/yellow (MET, ARF6, ITGB6), la alta expresión se asoció con una menor supervivencia, mientras que en los del módulo ME6/red (KATNAL2, NIPSNAP3B, MIR600HG) se observó el patrón inverso. Esta divergencia confirma que los dos módulos capturan señales pronósticas opuestas.




Figura 15. Curvas de Kaplan-Meier de los 3 genes más significativos de cada módulo. Fila superior: módulo ME4/yellow (MET, ARF6, ITGB6) (riesgo), donde la alta expresión se asocia con menor supervivencia. Fila inferior: módulo ME6/red (KATNAL2, NIPSNAP3B, MIR600HG) (protector), donde la alta expresión se asocia con mayor supervivencia.

4.6. Firma pronóstica LASSO-Cox

A partir de los 331 genes clave, se construyó un modelo pronóstico mediante regresión de Cox con penalización LASSO, que selecciona automáticamente los genes más relevantes para predecir la supervivencia eliminando aquellos cuya contribución es mínima. El modelo se entrenó con los datos de supervivencia de las muestras tumorales TCGA (n = 182), evaluando

10 valores del parámetro de regularización α (rango: 0,5-0,01) mediante validación cruzada estratificada de 5 folds. El valor óptimo ($\alpha = 0,08$) dio lugar a una firma de 12 genes con coeficientes no nulos (Tabla 2), de los cuales 5 presentaron coeficientes positivos (factor de riesgo) y 7 negativos (factor protector).

El rendimiento del modelo se evaluó mediante el índice de concordancia (C-index = 0,580; IC 95 % bootstrap: 0,522-0,640), que refleja la capacidad del modelo para ordenar correctamente a los pacientes según su riesgo. La estratificación en dos grupos según la mediana del score de riesgo mostró diferencias significativas en supervivencia (log-rank $p = 0,030$), con medianas de 17,48 meses en el grupo de alto riesgo frente a 22,83 meses en el de bajo riesgo.

Tabla 2. Firma genética pronóstica LASSO-Cox. Los genes se ordenan por valor absoluto del coeficiente.

Gen	Coeficiente LASSO	HR	Dirección
TAX1BP1	0,065	1,068	Factor de riesgo
RPL10P19	-0,020	0,980	Factor protector
ENSG00000260306	-0,025	0,975	Factor protector
EIF4G1	0,017	1,017	Factor de riesgo
NUDCD3	0,025	1,025	Factor de riesgo
COLQ	-0,016	0,984	Factor protector
ENSG00000249993	-0,016	0,984	Factor protector
CORO2A	0,009	1,009	Factor de riesgo
TNMD	-0,006	0,994	Factor protector
CEACAM1	0,005	1,005	Factor de riesgo
LINC01238	-0,004	0,996	Factor protector
ENSG00000274712	-0,001	0,999	Factor protector

Entre los genes seleccionados, TAX1BP1 presentó el coeficiente de mayor magnitud ($\beta = 0,065$; HR = 1,07), seguido de ENSG00000260306 ($\beta = -0,025$; HR = 0,98) y NUDCD3 ($\beta = 0,025$; HR = 1,03). Cabe destacar la presencia de CEACAM1, miembro de la familia CEACAM previamente implicada en PDAC, lo que aporta validez biológica a la firma. Tres genes carecen de símbolo oficial y se identifican únicamente por su código Ensembl.

La Figura 16 muestra la selección del parámetro de regularización α mediante validación cruzada de 5 folds. Se observa que el C-index alcanza su valor máximo en $\alpha = 0,08$, punto en el que el modelo retiene 12 genes con coeficientes no nulos. Valores de α más altos eliminan demasiados genes y reducen la capacidad predictiva, mientras que valores más bajos retienen un exceso de genes sin mejorar el rendimiento. La Figura 17 representa los coeficientes LASSO de los 12 genes seleccionados, donde las barras rojas indican factores de riesgo (coeficiente positivo) y las azules factores protectores (coeficiente negativo). TAX1BP1 destaca como el gen con mayor contribución absoluta a la firma.




Figura 16. Selección del parámetro de regularización α del modelo LASSO-Cox mediante validación cruzada.




Figura 17. Coeficientes LASSO de los 12 genes seleccionados en la firma pronóstica.

El modelo LASSO-Cox obtuvo un C-index de 0,580 (IC 95 % bootstrap: 0,522-0,640; 1000 repeticiones), lo que indica una capacidad discriminativa modesta pero superior al azar. A diferencia del análisis univariante de la sección 4.5, donde cada gen se evaluó de forma

individual, aquí el score de riesgo integra la expresión de los 12 genes simultáneamente, ponderada por los coeficientes LASSO. Los pacientes se estratificaron en grupos de alto y bajo riesgo (n = 91 cada uno) utilizando la mediana del score como punto de corte. La Figura 18 muestra las curvas de Kaplan-Meier resultantes, con una diferencia significativa en supervivencia global (log-rank p = 0,030) y medianas de 17,5 y 22,8 meses para los grupos de alto y bajo riesgo, respectivamente.




Figura 18. Curvas de Kaplan-Meier de los grupos de alto y bajo riesgo definidos por la firma LASSO-Cox de 12 genes. Log-rank p = 0,030.

Finalmente, la Figura 19 muestra la distribución del risk score entre los pacientes, coloreados según su estado vital (vivo/fallecido). Se observa una tendencia a mayor mortalidad en los pacientes con risk scores más elevados.




Figura 19. Distribución del risk score LASSO-Cox en los pacientes de TCGA-PAAD, coloreados según su estado vital.

4.7. Anotación funcional de la firma pronóstica

Para complementar la firma pronóstica de 12 genes, se realizó una anotación funcional de cada gen de forma individual. Al tratarse de un conjunto reducido de genes, un análisis de enriquecimiento clásico (ORA) no tendría suficiente potencia estadística, por lo que se optó por revisar manualmente la función de cada gen a partir de bases de datos biológicas (UniProt, GeneCards, Ensembl, The Human Protein Atlas) y literatura científica (PubMed). Para cada gen se consultaron sus funciones conocidas, los procesos biológicos asociados (GO), las rutas de señalización en las que participa (KEGG/Reactome) y su posible implicación en cáncer, especialmente en PDAC.

TAX1BP1 (Tax1 Binding Protein 1) - Factor de riesgo (coeficiente LASSO = +0,065; HR = 1,068). TAX1BP1 codifica un receptor de autofagia selectiva que participa en la regulación de la inmunidad innata (37). La proteína funciona como adaptador de la enzima A20/TNFAIP3, contribuyendo a inhibir las vías de señalización NF- κ B e IRF3 (37). A nivel de autofagia, TAX1BP1 se encarga de degradar sustratos marcados con ubiquitina, incluyendo moléculas de señalización inflamatoria como TICAM1 y MAVS (37). Un aspecto especialmente relevante para este trabajo es que TAX1BP1 también degrada la proteína STING1, que es importante para la respuesta inmune antitumoral: al degradar STING1, se reduce la producción de citoquinas y la activación de células T citotóxicas, lo que debilita la capacidad del sistema inmune para combatir el tumor (38, 39). El coeficiente positivo de TAX1BP1 en nuestra firma indica que niveles elevados de este gen se asocian a peor pronóstico, lo que podría explicarse por una mayor actividad autofágica favorable al tumor y la supresión de la respuesta inmune mediada por STING.

EIF4G1 (Eukaryotic Translation Initiation Factor 4 Gamma 1) - Factor de riesgo (coeficiente LASSO = +0,017; HR = 1,017). EIF4G1 codifica la subunidad principal del complejo eIF4F, que regula la iniciación de la traducción y está controlado por vías oncogénicas como AKT, MAPK y MYC (40). En PDAC, eIF4G1 se sobreexpresa en células tumorales y en fibroblastos asociados al tumor, y su alta expresión se ha asociado con peor supervivencia en tres cohortes independientes (41). Su inhibición en modelos murinos reduce la progresión tumoral y modifica el microambiente inmunosupresor, disminuyendo la infiltración de TAMs, MDSCs y Tregs (42). Su aparición como factor de riesgo en nuestra firma es coherente con estos hallazgos.

NUDCD3 (NudC Domain Containing 3) - Factor de riesgo (coeficiente LASSO = +0,025; HR = 1,025). NUDCD3 codifica una proteína necesaria para la estabilidad de la dineína y el correcto desarrollo de la mitosis (43). Tanto su silenciamiento como su sobreexpresión producen defectos mitóticos: arresto celular, células multinucleadas y problemas en la citocinesis (43, 44). La vía NudC/LIS1/dineína regula la mitosis y la migración celular, y su desregulación puede generar inestabilidad cromosómica (45). Aunque no se ha estudiado directamente en PDAC, el miembro relacionado NudCD1 se ha identificado como marcador pronóstico en cáncer colorrectal (46). Su coeficiente positivo sugiere que la sobreexpresión de NUDCD3 podría reflejar una mayor actividad proliferativa del tumor.

RPL10P19 (Ribosomal Protein L10 Pseudogene 19) - Factor protector (coeficiente LASSO = -0,020; HR = 0,980). RPL10P19 es un pseudogén derivado de RPL10, un componente de la subunidad 60S del ribosoma (47). Aunque los pseudogenes se consideraron durante mucho tiempo secuencias sin función, hoy se sabe que muchos generan lncRNA que actúan como ceRNA, secuestrando miRNA y regulando la expresión de otros genes (48, 49). Se han descrito pseudogenes con valor pronóstico en cáncer colorrectal (50) y leucemia pediátrica (51), y la expresión alterada de RPL10 se ha relacionado con la respuesta a quimioterapia en cáncer de páncreas (52). Su coeficiente negativo indica que una mayor expresión se asocia con mejor supervivencia.

AC092375.2 (ENSG00000260306) - Factor protector (coeficiente LASSO = -0,025; HR = 0,975). AC092375.2 es un lncRNA del módulo ME6/red de la red WGCNA (kME = 0,504), sin función descrita hasta la fecha. Los lncRNA participan en la regulación transcripcional, la estabilidad del mRNA y pueden actuar como esponjas de miRNA(53), y en PDAC se han identificado firmas de lncRNA capaces de estratificar pacientes por riesgo (54). Que aparezca un lncRNA no caracterizado en la firma es esperable en análisis transcriptómicos no supervisados, ya que el modelo selecciona señales pronósticas independientemente del conocimiento funcional previo. Su coeficiente negativo indica que niveles más altos se asocian con mejor supervivencia.

COLQ (Collagen Like Tail Subunit of Asymmetric Acetylcholinesterase) - Factor protector (coeficiente LASSO = -0,016; HR = 0,984). COLQ codifica la subunidad que ancla la acetilcolinesterasa (AChE) en la unión neuromuscular (55). Aunque se ha estudiado principalmente en síndromes miasténicos, su relación con la señalización colinérgica lo conecta con la biología tumoral: los receptores colinérgicos modulan la proliferación, la angiogénesis y la evasión inmune (56, 57). En PDAC, inhibidores de AChE han mostrado capacidad para

reducir la viabilidad e invasión celular (58). Su coeficiente negativo podría reflejar un efecto protector a través de la modulación de la señalización colinérgica en el microambiente tumoral.

CORO2A (Coronin 2A) - Factor de riesgo (coeficiente LASSO = +0,009; HR = 1,009). CORO2A codifica una proteína de unión a actina que forma parte del complejo correpresor NCoR, donde participa en la regulación de genes de respuesta inflamatoria mediante remodelación de la cromatina (66). Su desregulación se ha descrito en distintos tipos de cáncer, y se ha asociado con peor pronóstico en algunos contextos tumorales (67,68). Su coeficiente positivo en nuestra firma es coherente con su papel facilitador de la migración e invasión tumoral.

CEACAM1 (Carcinoembryonic Antigen-Related Cell Adhesion Molecule 1) - Factor de riesgo (coeficiente LASSO = +0,005; HR = 1,005). CEACAM1 es un miembro de la familia CEACAM que actúa como checkpoint inmunológico: al expresarse en células tumorales, interacciona con CEACAM1 de los linfocitos T y NK inhibiendo su activación (69). En PDAC, CEACAM1 está sobreexpresado y sus niveles elevados se han asociado con estadios más avanzados y peor supervivencia (70). Además, marca las células T reguladoras más supresoras dentro del microambiente tumoral (71). Su presencia como factor de riesgo es consistente con su papel en la supresión de la respuesta inmune antitumoral.

TNMD (*Tenomodulin*) - Factor protector (coeficiente LASSO = -0,006; HR = 0,994). TNMD codifica una proteína transmembrana con actividad antiangiogénica, expresada principalmente en tejidos conectivos hipovasculares (72). También participa en la diferenciación de adipocitos y el metabolismo de glucosa y lípidos (73). Un análisis pan-cáncer reciente ha mostrado que su expresión se correlaciona con la infiltración de células NK y negativamente con células T reguladoras (74). Su coeficiente negativo sugiere un posible efecto protector relacionado con su actividad antiangiogénica o con una modulación favorable del microambiente inmune.

LINC01238 - Factor protector (coeficiente LASSO = -0,004; HR = 0,996). LINC01238 es un lncRNA del módulo ME6/red de la red WGCNA. Los lncRNA participan en múltiples procesos reguladores como la estabilidad del mRNA y la función de esponja de miRNA(53), y se han descrito numerosos lncRNA con valor pronóstico en cáncer (75). Aunque LINC01238 no ha sido caracterizado individualmente, su selección por el modelo LASSO indica que contribuye a la predicción de supervivencia. Su coeficiente negativo asocia niveles más altos con mejor pronóstico.

ENSG00000249993 - Factor protector (coeficiente LASSO = -0,016; HR = 0,984). Se trata de un transcrito no codificante sin símbolo génico oficial ni función descrita en las bases de datos

consultadas (GeneCards, Ensembl, UniProt). Al igual que AC092375.2, pertenece al módulo ME6/red y fue seleccionado por el modelo LASSO por su contribución a la predicción de supervivencia. La identificación de transcritos no caracterizados con valor pronóstico es frecuente en análisis transcriptómicos a gran escala (54). Su coeficiente negativo indica una asociación protectora.

ENSG00000274712 - Factor protector (coeficiente LASSO = $-0,001$; HR = 0,999). Este gen está clasificado como pseudogén de BPTF (Bromodomain PHD Finger Transcription Factor), un factor de remodelación de la cromatina implicado en varios tipos de cáncer (76). Aunque no codifica una proteína funcional, los pseudogenes pueden generar lncRNA con funciones reguladoras (48). Su coeficiente es el de menor magnitud de toda la firma ($-0,001$), indicando una contribución marginal pero no nula a la predicción.

En conjunto, los genes anotados de la firma abarcan procesos biológicos diversos: autofagia y regulación inmune vía STING (TAX1BP1), control de la traducción y remodelación del microambiente inmunosupresor (EIF4G1), regulación del huso mitótico e inestabilidad cromosómica (NUDCD3), checkpoint inmunológico mediado por adhesión celular (CEACAM1), remodelación de cromatina y respuesta inflamatoria (CORO2A), regulación post-transcripcional por pseudogenes ribosomales (RPL10P19), actividad antiangiogénica y modulación inmune (TNMD), señalización no codificante (AC092375.2, LINC01238, ENSG00000249993, ENSG00000274712) y modulación colinérgica del microambiente tumoral (COLQ). Esta variedad es coherente con la complejidad del PDAC y sugiere que la firma recoge distintos aspectos de la biología del tumor, lo que podría explicar su capacidad para diferenciar entre los grupos de alto y bajo riesgo (log-rank $p = 0,030$).

5. Discusión

El objetivo de este trabajo fue identificar genes candidatos a biomarcadores pronósticos en PDAC mediante la integración de análisis de expresión diferencial, redes de coexpresión génica (WGCNA) y modelos de supervivencia. A continuación se discuten los principales resultados obtenidos.

5.1. Expresión diferencial

El análisis con DESeq2 identificó 32 113 DEGs entre tejido tumoral y normal, de los cuales 5 036 estaban sobreexpresados y 27 077 infraexpresados en tumor. Este número es elevado en comparación con otros estudios de PDAC, lo que probablemente se explica por la

integración de datos de dos fuentes distintas (TCGA y GTEx) y por el tamaño muestral (183 tumores y 167 normales), ya que un mayor número de muestras aumenta la potencia estadística y permite detectar diferencias más pequeñas (28). Además, la corrección batch con ComBat (59), aunque necesaria para combinar ambas fuentes, puede introducir cierto ruido residual que contribuya a un mayor número de genes significativos.

Otros estudios en PDAC que utilizaron solo datos de TCGA o microarrays han reportado cifras de DEGs considerablemente menores. Por ejemplo, Liu et al. (60) identificaron alrededor de 800 DEGs a partir de datasets de microarrays, y Lu et al. (61) reportaron unos 2000 genes. La diferencia con nuestros resultados se debe principalmente al tipo de dato (RNA-seq frente a microarray), a los umbrales de significancia utilizados y al diseño del estudio. No obstante, el filtrado posterior con WGCNA permitió reducir este conjunto a un número más manejable de genes clave.

5.2. Módulos de coexpresión y su significado funcional

El análisis WGCNA identificó 18 módulos de coexpresión, de los cuales dos mostraron las correlaciones más relevantes con mortalidad: ME6/red ($r = -0,251$) y ME4/yellow ($r = 0,240$). Que estos dos módulos presenten correlaciones de signo opuesto sugiere que capturan mecanismos biológicos diferenciados: el módulo ME4/yellow agrupa genes cuya mayor expresión se asocia a peor pronóstico, mientras que ME6/red presenta el patrón inverso. Estudios previos en PDAC han descrito la importancia de vías metabólicas, de proliferación celular y de respuesta inmune en la progresión tumoral (5, 8, 62).

La correlación negativa de ME6/red con mortalidad podría reflejar mecanismos protectores como una mayor actividad inmune o programas de diferenciación celular, en línea con lo descrito sobre el papel del microambiente tumoral en PDAC (21). No obstante, esta correlación se calcula a nivel de eigengene, por lo que representa una señal agregada del módulo y no implica que cada gen individual tenga necesariamente un efecto protector.

En conjunto, la diferenciación entre ambos módulos indica que el pipeline logró separar componentes biológicos distintos dentro del transcriptoma tumoral, lo cual apoya la validez del enfoque utilizado.

5.3. Genes clave y análisis de supervivencia

La integración de genes hub ($kME > 0,5$ y $|GS_death| > 0,15$) procedentes de los módulos asociados a mortalidad con los DEGs ($p_{adj} < 0,05$ y $|\log_2FC| > 1$) dio lugar a 331 genes clave.

El análisis de supervivencia sobre los 225 genes con símbolo conocido identificó 154 con asociación significativa con la supervivencia global tras corrección por test múltiple ($FDR < 0,05$), lo que indica que una proporción importante de los genes clave tiene valor pronóstico. En el módulo ME4/yellow, los genes con menor FDR fueron MET ($FDR = 1,52 \times 10^{-5}$), ARF6 ($FDR = 1,39 \times 10^{-4}$) e ITGB6 ($FDR = 1,39 \times 10^{-4}$), donde la alta expresión se asoció con menor supervivencia. En el módulo ME6/red, destacaron KATNAL2 ($FDR = 3,74 \times 10^{-4}$), NIPSNAP3B ($FDR = 6,96 \times 10^{-4}$) y MIR600HG ($FDR = 9,40 \times 10^{-4}$), con el patrón inverso: la alta expresión se asoció con mejor pronóstico.

MET fue el gen con mayor efecto pronóstico ($HR = 1,943$; IC 95 %: 1,527–2,473; $FDR = 1,52 \times 10^{-5}$). MET codifica el receptor del factor de crecimiento hepatocitario (HGF/MET), una vía que promueve la invasión, la migración celular y la angiogénesis, y cuya sobreexpresión se ha descrito previamente en PDAC asociándose con estadios más avanzados y peor pronóstico (5, 32). Otros genes del módulo yellow con HR elevados fueron ITGB6 ($HR = 1,885$), un receptor de integrinas implicado en la invasión de la matriz extracelular, y LDHA ($HR = 1,768$), una enzima clave de la glucólisis cuya sobreexpresión se ha relacionado con agresividad tumoral en varios tipos de cáncer (62). En el módulo red, KATNAL2 presentó el HR más bajo ($HR = 0,569$; IC 95 %: 0,432–0,750), indicando un efecto protector significativo.

La coherencia entre ambos análisis (Kaplan-Meier y Cox univariante) y la clara separación entre genes de riesgo (módulo yellow) y protectores (módulo red) refuerza la validez de la selección de módulos realizada por WGCNA y confirma que los dos módulos capturan señales pronósticas opuestas.

5.4. Firma pronóstica LASSO-Cox

El modelo LASSO-Cox seleccionó una firma de 12 genes a partir de los 331 genes clave, con un C-index de 0,580 (IC 95 %: 0,522–0,640) y una diferencia significativa entre los grupos de alto y bajo riesgo (log-rank $p = 0,030$; medianas de supervivencia: 17,5 frente a 22,8 meses). Este C-index es modesto, pero hay que tener en cuenta que el PDAC es un cáncer muy agresivo y heterogéneo, lo que dificulta la predicción pronóstica en general. Estudios similares que han combinado WGCNA con LASSO-Cox en otros tumores, como cáncer gástrico (14) o de cérvix (15), han obtenido C-index entre 0,60 y 0,75, aunque en la mayoría de casos contaban con cohortes de validación externas de las que este trabajo carece. En PDAC, otros trabajos han utilizado enfoques similares combinando WGCNA con análisis de supervivencia

para identificar genes pronósticos (18, 63), aunque las firmas y metodologías varían entre estudios, lo que dificulta una comparación directa de rendimientos.

La firma incluye 5 genes asociados a mayor riesgo (TAX1BP1, EIF4G1, NUDCD3, CORO2A y CEACAM1) y 7 con efecto protector (RPL10P19, AC092375.2, COLQ, ENSG00000249993, TNMD, LINC01238 y ENSG00000274712). Como se describe en la sección de anotación funcional, estos genes participan en procesos bastante variados: autofagia y supresión inmune (TAX1BP1), control de la traducción (EIF4G1), regulación mitótica (NUDCD3), invasión celular (CORO2A), checkpoint inmunológico (CEACAM1), inhibición de angiogénesis (TNMD), señalización colinérgica (COLQ) y regulación no codificante (RPL10P19 y varios lncRNA). Que la firma incluya genes de procesos tan distintos tiene sentido con la complejidad del PDAC y sugiere que el modelo está recogiendo señales de diferentes aspectos de la biología del tumor.

Un punto a tener en cuenta es que los datos proceden de RNA-seq en bloque, donde cada muestra mezcla la señal del tumor con la del estroma, que en PDAC puede representar hasta el 80 % del tejido (9). Esto significa que algunos de los genes de la firma podrían reflejar señales del microambiente y no solo de las células tumorales. Para separar estas contribuciones harían falta técnicas como RNA-seq de célula única o deconvolución computacional (8,9).

Otro aspecto llamativo es que los genes más significativos del análisis univariante no coinciden con los del LASSO. MET, que fue el gen con mayor efecto pronóstico individual (HR = 1,943), no aparece en la firma, y de los 154 genes significativos en el Cox univariante solo 4 fueron seleccionados. Esto se debe a que los dos análisis buscan cosas distintas: el univariante evalúa cada gen por separado, mientras que el LASSO busca la mejor combinación descartando genes redundantes. Si varios genes del mismo módulo se expresan de forma similar, el LASSO no necesita incluirlos todos porque aportarían información repetida, y prefiere quedarse con genes que se complementen entre sí aunque individualmente sean menos significativos.

Por último, desde un punto de vista práctico, una firma de 12 genes tiene un tamaño manejable para una posible aplicación clínica, ya que podría medirse con técnicas como qRT-PCR o paneles de expresión dirigidos, a diferencia de firmas más grandes que serían más difíciles de implementar (15, 63).

5.5. Validación con genes de referencia

Como control de calidad, se verificó la presencia de 13 genes previamente descritos como relevantes en PDAC (KRAS, TP53, CDKN2A, SMAD4, MUC1, MUC4, MSLN, S100A4, CEACAM6, KRT19, VIM, S100P y CEACAM5) a lo largo del pipeline. Todos fueron detectados en la matriz inicial y la mayoría clasificados como DEGs (1,5,6). Aunque estos genes no aparecieron en la firma final de 12 genes, su detección en las etapas intermedias apoya la coherencia biológica del análisis y sugiere que el pipeline es capaz de capturar señales biológicas conocidas.

5.6. Limitaciones

Este trabajo presenta varias limitaciones que deben tenerse en cuenta.

En primer lugar, todos los análisis se realizaron sobre los mismos datos (TCGA-PAAD), sin comprobar si los resultados se mantienen en un grupo de pacientes diferente. La validación cruzada que se utilizó para ajustar el modelo LASSO-Cox ayuda a evitar el sobreajuste, pero no sustituye a una validación con datos independientes. Para confirmar que la firma es realmente útil habría que evaluarla en otras cohortes, como las de ICGC o GEO. Además, los pacientes de TCGA-PAAD son mayoritariamente de estadios resecables, por lo que no sabemos si la firma funcionaría igual en pacientes con enfermedad más avanzada.

En segundo lugar, al combinar datos de dos fuentes distintas (TCGA y GTEx) pueden aparecer diferencias técnicas entre ellas, ya que cada proyecto utilizó sus propios protocolos de procesamiento. Aunque se aplicó ComBat para corregir este efecto (59), no se puede descartar que queden diferencias residuales que hayan influido en los resultados.

En tercer lugar, la diferencia en supervivencia entre los dos grupos de riesgo (17,5 frente a 22,8 meses) es de unos 5 meses, lo cual es una diferencia modesta desde el punto de vista clínico. Esto refuerza el carácter exploratorio de la firma. Para valorar si tendría utilidad real en la práctica clínica habría que compararla con los factores pronósticos (como el estadio tumoral o el tipo de resección) y combinarla con variables clínicas que no se incluyeron en este modelo.

En cuarto lugar, el estudio se basa únicamente en datos de expresión génica (ARN), sin incorporar otro tipo de información como datos genómicos, epigenómicos o proteómicos, que podrían dar una visión más completa. Tampoco se realizó ningún tipo de validación experimental: para saber si genes como TAX1BP1 o EIF4G1 realmente tienen un papel activo

en la agresividad del tumor, harían falta experimentos en laboratorio con líneas celulares de PDAC y modelos animales.

Por último, el RNA-seq en bloque que se utilizó en este estudio no permite saber si la expresión que detectamos viene de las células tumorales, del estroma o del infiltrado inmune. En PDAC esto es especialmente importante porque el estroma puede suponer la mayor parte del tejido tumoral. Para resolver esto, futuros trabajos podrían utilizar tecnologías de célula única o transcriptómica espacial, que sí permiten distinguir de qué tipo celular procede cada señal.

5.7. Perspectivas futuras

Los resultados abren varias líneas de trabajo futuro. El paso más importante sería validar la firma de 12 genes en cohortes independientes para comprobar si se reproduce. Además, incluir variables clínicas (estadio, grado, tratamiento) en el modelo de Cox podría mejorar su capacidad predictiva.

A nivel funcional, sería interesante confirmar experimentalmente el papel de TAX1BP1, EIF4G1 y los demás genes de la firma en la progresión del PDAC, por ejemplo con ensayos de silenciamiento génico o modelos in vitro.

6. Conclusiones

Las principales conclusiones de este trabajo son las siguientes:

1. El análisis de expresión diferencial entre tejido tumoral y normal de páncreas identificó 32 113 DEGs, reflejando una amplia reprogramación transcriptómica en el PDAC.
2. La red de coexpresión WGCNA identificó 18 módulos, de los cuales ME6/red ($r = -0,251$) y ME4/yellow ($r = 0,240$) mostraron las correlaciones más relevantes con mortalidad, capturando señales pronósticas opuestas: genes de riesgo y genes protectores, respectivamente.
3. Se identificaron 331 genes clave en la intersección entre DEGs estrictos y genes hub de los módulos asociados a mortalidad. De los 225 con símbolo conocido, 154 mostraron asociación significativa con la supervivencia global tras corrección por test múltiple ($FDR < 0,05$), destacando MET como el gen con mayor efecto pronóstico ($HR = 1,943$; $FDR = 1,52 \times 10^{-5}$).
4. La firma pronóstica LASSO-Cox de 12 genes (TAX1BP1, NUDCD3, EIF4G1, CORO2A, CEACAM1, COLQ, RPL10P19, TNMD, LINC01238 y tres transcritos sin símbolo HGNC

oficial) alcanzó un C-index de 0,580 (IC 95 %: 0,522-0,640) y estratificó a los pacientes en grupos de alto y bajo riesgo con una diferencia significativa en supervivencia (log-rank $p = 0,030$; medianas de 17,5 frente a 22,8 meses). La capacidad discriminativa fue modesta, lo que refleja la alta heterogeneidad del PDAC.

5. La anotación funcional de la firma reveló que los 12 genes mencionados seleccionados participan en procesos diversos como autofagia, evasión inmune, regulación mitótica, control de la traducción y señalización no codificante, lo cual es coherente con la complejidad molecular del PDAC.
6. El pipeline bioinformático propuesto demostró coherencia biológica al identificar genes y vías previamente descritos en PDAC, validando el enfoque de integración DEGs-WGCNA-LASSO-Cox.
7. La principal limitación del estudio es la ausencia de validación externa e experimental, por lo que los resultados deben considerarse exploratorios y requerirán confirmación en cohortes independientes y ensayos funcionales.

7. Referencias

1. Sung H, Ferlay J, Siegel RL, et al. Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. *CA Cancer J Clin.* 2021;71(3):209–249.
2. Siegel RL, Giaquinto AN, Jemal A. Cancer statistics, 2024. *CA Cancer J Clin.* 2024;74(1):12–49.
3. Rahib L, Smith BD, Aizenberg R, Rosenzweig AB, Fleshman JM, Matrisian LM. Projecting cancer incidence and deaths to 2030: the unexpected burden of thyroid, liver, and pancreas cancers in the United States. *Cancer Res.* 2014;74(11):2913–2921.
4. Klein AP. Pancreatic cancer epidemiology: understanding the role of lifestyle and inherited risk factors. *Nat Rev Gastroenterol Hepatol.* 2021;18(7):493–502.
5. Stefanoudakis D, Frountzas M, Schizas D, et al. Significance of TP53, CDKN2A, SMAD4 and KRAS in Pancreatic Cancer. *Curr Issues Mol Biol.* 2024;46(4):2827–2844.
6. Zhao M, Mishra L, Deng CX. The role of TGF- β /SMAD4 signaling in cancer. *Int J Biol Sci.* 2018;14(2):111–123.

7. Waters AM, Der CJ. KRAS: The Critical Driver and Therapeutic Target for Pancreatic Cancer. *Cold Spring Harb Perspect Med*. 2018;8(9):a031435.
8. Neesse A, Algul H, Tuveson DA, Gress TM. Stromal biology and therapy in pancreatic cancer: a changing paradigm. *Gut*. 2015;64(9):1476–1484.
9. Ho WJ, Jaffee EM, Zheng L. The tumour microenvironment in pancreatic cancer - clinical challenges and opportunities. *Nat Rev Clin Oncol*. 2020;17(9):527–540.
10. Biomarkers Definitions Working Group. Biomarkers and surrogate endpoints: preferred definitions and conceptual framework. *Clin Pharmacol Ther*. 2001;69(3):89–95.
11. Ballehaninna UK, Chamberlain RS. The clinical utility of serum CA 19-9 in the diagnosis, prognosis and management of pancreatic adenocarcinoma: An evidence based appraisal. *J Gastrointest Oncol*. 2012;3(2):105–119.
12. Goonetilleke KS, Siriwardena AK. Systematic review of carbohydrate antigen (CA 19-9) as a biochemical marker in the diagnosis of pancreatic cancer. *Eur J Surg Oncol*. 2007;33(3):266–270.
13. Langfelder P, Horvath S. WGCNA: an R package for weighted correlation network analysis. *BMC Bioinformatics*. 2008;9:559.
14. Zhang B, Wu Q, Li B, Wang D, Wang L, Zhou YL. A weighted gene coexpression network analysis-derived prognostic model for predicting prognosis and immune infiltration in gastric cancer. *Front Oncol*. 2021;11:554779.
15. Chen X, Li T, Yang X, et al. Determination of a six-gene prognostic model for cervical cancer based on WGCNA combined with LASSO and Cox-PH analysis. *World J Surg Oncol*. 2021;19(1):270.
16. Hu G, Niu W, Ge J, Xuan J, Liu Y, Li M, et al. Identification of thyroid cancer biomarkers using WGCNA and machine learning. *Eur J Med Res*. 2025;30(1):244.
17. Giulietti M, Occhipinti G, Principato G, Piva F. Weighted gene coexpression network analysis reveals key genes involved in pancreatic ductal adenocarcinoma development. *Cell Oncol (Dordr)*. 2016;39(4):379–388.
18. Nisar M, Paracha RZ, Arshad I, et al. Integrated Analysis of Microarray and RNA-Seq Data for the Identification of Hub Genes and Networks Involved in Pancreatic Cancer. *Front Genet*. 2021;12:663787.

19. Ren T, Xue X, Wang X, et al. Bioinformatic and experimental analyses of key biomarkers in pancreatic cancer. *Exp Ther Med*. 2021;22:1359.
20. Wu H, Tan W, Tao X, et al. Identification and functional analysis of novel oncogene DDX60L in pancreatic ductal adenocarcinoma. *BMC Genomics*. 2021;22:833.
21. Mantini G, Agostini A, Tufo M, et al. Weighted gene coexpression network analysis reveals key stromal prognostic markers in pancreatic cancer. *Sci Rep*. 2024;14:31769.
22. Hong M, Tao S, Zhang L, et al. RNA sequencing: new technologies and applications in cancer research. *J Hematol Oncol*. 2020;13(1):166.
23. Dobin A, Davis CA, Schlesinger F, Drenkow J, Zaleski C, Jha S, et al. STAR: ultrafast universal RNA-seq aligner. *Bioinformatics*. 2013;29(1):15–21.
24. Colaprico A, Silva TC, Olsen C, et al. TCGAAbiolinks: an R/Bioconductor package for integrative analysis of TCGA data. *Nucleic Acids Res*. 2016;44(8):e71.
25. Hutter C, Zenklusen JC. The Cancer Genome Atlas: Creating Lasting Value beyond Its Data. *Cell*. 2018;173(2):283–285.
26. GTEx Consortium. The Genotype-Tissue Expression (GTEx) project. *Nat Genet*. 2013;45(6):580–585.
27. Waskom ML. seaborn: statistical data visualization. *J Open Source Softw*. 2021;6(60):3021.
28. Love MI, Huber W, Anders S. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biol*. 2014;15(12):550.
29. Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. *J R Stat Soc Series B*. 1995;57(1):289–300.
30. Langfelder P, Horvath S. Eigengene networks for studying the relationships between coexpression modules. *BMC Syst Biol*. 2007;1:54.
31. Cohen J. *Statistical Power Analysis for the Behavioral Sciences*. 2nd ed. Hillsdale, NJ: Lawrence Erlbaum Associates; 1988.
32. Waddell N, Pajic M, Patch AM, et al. Whole genomes redefine the mutational landscape of pancreatic cancer. *Nature*. 2015;518(7540):495–501.
33. Tibshirani R. The lasso method for variable selection in the Cox model. *Stat Med*. 1997;16(4):385–395.

34. Hunter JD. Matplotlib: A 2D Graphics Environment. *Comput Sci Eng.* 2007;9(3):90–95.
35. Gene Ontology Consortium. The Gene Ontology resource: enriching a GOld mine. *Nucleic Acids Res.* 2021;49(D1):D325–D334.
36. Kanehisa M, Furumichi M, Sato Y, Kawashima M, Ishiguro-Watanabe M. KEGG for taxonomy-based analysis of pathways and genomes. *Nucleic Acids Res.* 2023;51(D1):D587–D592.
37. White J, Suklabaidya S, Vo MT, Choi YB, Harhaj EW. Multifaceted roles of TAX1BP1 in autophagy. *Autophagy.* 2023;19(1):44–53.
38. Zhang R, Yu C, Zeh HJ, Kroemer G, Klionsky DJ, Tang D, Kang R. TAX1BP1-dependent autophagic degradation of STING1 impairs anti-tumor immunity. *Autophagy.* 2025;21(5):1128–1141.
39. Yang S, Wang X, Contino G, et al. Pancreatic cancers require autophagy for tumor growth. *Genes Dev.* 2011;25(7):717–729.
40. Bhat M, Robichaud N, Hulea L, Sonenberg N, Pelletier J, Topisirovic I. Targeting the translation machinery in cancer. *Nat Rev Drug Discov.* 2015;14(4):261–278.
41. Goh TS, Ha M, Lee JS, Jeong DC, Jung ES, Han ME, et al. Prognostic significance of EIF4G1 in patients with pancreatic ductal adenocarcinoma. *Onco Targets Ther.* 2019;12:2853–2859.
42. He L, Zhang X, Shi F, Zhang H, Chen Y, Sun K, et al. Reprograming immunosuppressive microenvironment by eIF4G1 targeting to eradicate pancreatic ductal adenocarcinoma. *Cell Rep Med.* 2024;5(10):101731.
43. Zhou T, Zimmerman W, Liu X, Erikson RL. A mammalian NudC-like protein essential for dynein stability and cell viability. *Proc Natl Acad Sci U S A.* 2006;103(24):9039–9044.
44. Cai Y, Yang Y, Shen M, Zhou T. Inhibition of cytokinesis by overexpression of NudCL that is localized to the centrosome and midbody. *Cell Res.* 2009;19(11):1305–1308.
45. Fu Q, Wang W, Zhou T, Yang Y. Emerging roles of NudC family: from molecular regulation to clinical implications. *Sci China Life Sci.* 2016;59(5):455–462.
46. Feng M, Dong Y, Li X, et al. NudCD1 as a prognostic marker in colorectal cancer and its role in the upregulation of cellular spindle assembly checkpoint genes and LIS1 pathways. *BMC Cancer.* 2022;22(1):981.

47. Loenarz C, Sekirnik R, Thalhammer A, et al. Hydroxylation of the eukaryotic ribosomal decoding center affects translational accuracy. *Proc Natl Acad Sci U S A*. 2014;111(11):4019–4024.
48. Poliseno L, Salmena L, Zhang J, et al. A coding-independent function of gene and pseudogene mRNAs regulates tumour biology. *Nature*. 2010;465(7301):1033–1038.
49. Salmena L, Poliseno L, Tay Y, et al. A ceRNA hypothesis: the Rosetta Stone of a hidden RNA language? *Cell*. 2011;146(3):353–358.
50. Li Z, Zhou J, Gu L, Zhang B. Pseudogenes and the associated ceRNA network as potential prognostic biomarkers for colorectal cancer. *Sci Rep*. 2022;12(1):17787.
51. Nakamura-Garcia AK, Kuijjer ML, Espinal-Enriquez J. Pseudogene coexpression networks reveal a robust prognostic signature for pediatric B-ALL survival. *Cancer Res Commun*. 2026;6(4):842–856.
52. De Las Heras-Rubio A, Perucho L, Paciucci R, et al. Ribosomal proteins as novel players in tumorigenesis. *Cancer Metastasis Rev*. 2014;33(1):115–141.
53. Gutschner T, Diederichs S. The hallmarks of cancer: a long non-coding RNA point of view. *RNA Biol*. 2012;9(6):703–719.
54. Zhou M, Zhang Z, Zhao H, et al. An immune-related six-lncRNA signature to improve prognosis prediction of glioblastoma multiforme. *Mol Neurobiol*. 2018;55(5):3684–3697.
55. Krejci E, Thomine S, Boschetti N, et al. The mammalian gene of acetylcholinesterase-associated collagen. *J Biol Chem*. 1997;272(36):22840–22847.
56. Aronowitz AL, Ali SR, Glaun MDE, Amit M. Acetylcholine in carcinogenesis and targeting cholinergic receptors in oncology. *Adv Biol (Weinh)*. 2022;6(9):e2200053.
57. Pavlov VA, Tracey KJ. The cholinergic anti-inflammatory pathway. *Brain Behav Immun*. 2005;19(6):493–499.
58. Hering NA, Lowe H, Herde N, et al. Molecular and functional analysis of choline transporters and antitumor effects of choline transporter-like protein 1 inhibitors in human pancreatic cancer cells. *Int J Mol Sci*. 2020;21(15):5190.
59. Johnson WE, Li C, Rabinovic A. Adjusting batch effects in microarray expression data using empirical Bayes methods. *Biostatistics*. 2007;8(1):118–127.

60. Liu L, Wang S, Cen C, et al. Identification of differentially expressed genes in pancreatic ductal adenocarcinoma and normal pancreatic tissues based on microarray datasets. *Mol Med Rep.* 2019;20(2):1901–1914.
61. Lu W, Li N, Liao F. Identification of Key Genes and Pathways in Pancreatic Cancer Gene Expression Profile by Integrative Analysis. *Genes (Basel).* 2019;10(8):612.
62. Vander Heiden MG, Cantley LC, Thompson CB. Understanding the Warburg effect: the metabolic requirements of cell proliferation. *Science.* 2009;324(5930):1029–1033.
63. Salihoglu R, Nieves J, Dandekar G, et al. Machine learning and gene network integration reveal prognostic subnetworks and biomarkers in pancreatic cancer. *Comput Struct Biotechnol J.* 2025;27:4151–4162.
64. Cancer Genome Atlas Research Network. Integrated Genomic Characterization of Pancreatic Ductal Adenocarcinoma. *Cancer Cell.* 2017;32(2):185–203.e13.
65. Hemphill JF. Interpreting the magnitudes of correlation coefficients. *Am Psychol.* 2003;58(1):78–79.
66. Huang W, Ghisletti S, Saijo K, et al. Coronin 2A mediates actin-dependent de-repression of inflammatory response genes. *Nature.* 2011;470(7334):414–418.
67. Koma A, Kase-Kato I, Asai S, Minemura C, Tsuneizumi K, Oshima S, et al. Molecular Pathogenesis of the Coronin Family: CORO2A Facilitates Migration and Invasion Abilities in Oral Squamous Cell Carcinoma. *Int J Mol Sci.* 2021;22(23):12684.
68. Tang J, Li Y, Wang X, et al. Constructing an immune-related prognostic model and exploring the function of HMGB3, TNFSF4, and CORO2A in breast cancer. *Transl Cancer Res.* 2023;12(10):2579–2595.
69. Dankner M, Gray-Owen SD, Huang YH, Blumberg RS, Beauchemin N. CEACAM1 as a multi-purpose target for cancer immunotherapy. *Oncoimmunology.* 2017;6(7):e1328336.
70. Gebauer F, Wicklein D, Horst J, Sundermann P, Maar H, Streichert T, et al. Carcinoembryonic antigen-related cell adhesion molecules (CEACAM) 1, 5 and 6 as biomarkers in pancreatic cancer. *PLoS One.* 2014;9(11):e113023.
71. Jeon SH, Kang M, Jeon M, Chung Y, Kim AR, Lee YJ, et al. CEACAM1 marks highly suppressive intratumoral regulatory T cells for targeted depletion therapy. *Clin Cancer Res.* 2023;29(9):1794–1806.

72. Docheva D, Hunziker EB, Fässler R, et al. Tenomodulin is necessary for tenocyte proliferation and tendon maturation. *Mol Cell Biol.* 2005;25(2):699–705.
73. Senol-Cosar O, Flach RJR, DiStefano M, et al. Tenomodulin promotes human adipocyte differentiation and beneficial visceral adipose tissue expansion. *Nat Commun.* 2016;7:10686.
74. Chen J, Hu Q, Zhang C, Zhao A, et al. Tendomodulin in pan-cancer analysis: exploring its impact on immune modulation and uncovering functional insights in colorectal cancer. *BMC Cancer.* 2025;25:239.
75. Huarte M. The emerging role of lncRNAs in cancer. *Nat Med.* 2015;21(11):1253–1261.
76. Dar AA, Nosrati M, Bezrookove V, et al. The role of BPTF in melanoma progression and in response to BRAF-targeted therapy. *J Natl Cancer Inst.* 2015;107(5):djv034.
77. Goldman MJ, Craft B, Hastie M, et al. Visualizing and interpreting cancer genomics data via the Xena platform. *Nat Biotechnol.* 2020;38(6):675–678.

7.1 Declaración de uso de Inteligencia Artificial

En la elaboración de este trabajo se utilizó el modelo Claude Opus 4 (Anthropic) como herramienta de apoyo en las siguientes tareas:

- Asistencia en la depuración y optimización de scripts de R y Python, así como en la estructuración del flujo de trabajo bioinformático.
- Búsqueda y verificación de referencias bibliográficas.
- Corrección gramatical y ortográfica del manuscrito.
- Apoyo en la elaboración de figuras y esquemas.

El diseño del estudio, la selección de la metodología, la ejecución del pipeline bioinformático y la interpretación de los resultados fueron realizados por la autora bajo la supervisión y dirección de la tutora. Todos los contenidos generados o sugeridos por la herramienta fueron revisados, validados y adaptados por la autora antes de su incorporación al manuscrito.

8. Anexo

Tabla A1. Resultados del análisis de regresión de Cox univariante para los 154 genes clave con significación estadística tras corrección FDR (Benjamini-Hochberg). Se muestran el hazard ratio (HR), el intervalo de confianza al 95 %, el p-valor, la concordancia, la dirección del efecto y el valor de FDR. Los genes se ordenan por p-valor.

Gen	Ensembl	Módulo	HR	IC 95% inf.	IC 95% sup.	p-valor	Concordancia	Riesgo	FDR
MET	ENSG00000105976	yellow	1,943	1,527	2,473	$6,76 \times 10^{-8}$	0,665	Riesgo	$1,52 \times 10^{-5}$
ARF6	ENSG00000165527	yellow	1,635	1,340	1,994	$1,25 \times 10^{-6}$	0,632	Riesgo	$1,39 \times 10^{-4}$
ITGB6	ENSG00000115221	yellow	1,885	1,452	2,447	$1,94 \times 10^{-6}$	0,647	Riesgo	$1,39 \times 10^{-4}$
FAM83A	ENSG00000147689	yellow	1,556	1,295	1,870	$2,48 \times 10^{-6}$	0,637	Riesgo	$1,39 \times 10^{-4}$
ADAM10	ENSG00000137845	yellow	1,632	1,325	2,009	$3,94 \times 10^{-6}$	0,630	Riesgo	$1,59 \times 10^{-4}$
MYEOV	ENSG00000172927	yellow	1,668	1,341	2,074	$4,23 \times 10^{-6}$	0,645	Riesgo	$1,59 \times 10^{-4}$
LAMA3	ENSG00000053747	yellow	1,688	1,345	2,118	$6,32 \times 10^{-6}$	0,640	Riesgo	$1,80 \times 10^{-4}$
LDHA	ENSG00000134333	yellow	1,768	1,380	2,264	$6,39 \times 10^{-6}$	0,640	Riesgo	$1,80 \times 10^{-4}$
ANO1	ENSG00000131620	yellow	1,687	1,339	2,125	$9,17 \times 10^{-6}$	0,627	Riesgo	$1,92 \times 10^{-4}$
TES	ENSG00000135269	yellow	1,606	1,302	1,981	$9,52 \times 10^{-6}$	0,635	Riesgo	$1,92 \times 10^{-4}$
CD2AP	ENSG00000198087	yellow	1,684	1,334	2,124	$1,11 \times 10^{-5}$	0,644	Riesgo	$1,92 \times 10^{-4}$
RALB	ENSG00000144118	yellow	1,601	1,297	1,976	$1,20 \times 10^{-5}$	0,623	Riesgo	$1,92 \times 10^{-4}$
KRT7	ENSG00000135480	yellow	1,814	1,388	2,369	$1,28 \times 10^{-5}$	0,657	Riesgo	$1,92 \times 10^{-4}$
CAST	ENSG00000153113	yellow	1,532	1,265	1,857	$1,30 \times 10^{-5}$	0,636	Riesgo	$1,92 \times 10^{-4}$
SERPINB5	ENSG00000206075	yellow	1,611	1,300	1,996	$1,30 \times 10^{-5}$	0,646	Riesgo	$1,92 \times 10^{-4}$
GJB3	ENSG00000188910	yellow	1,673	1,326	2,112	$1,47 \times 10^{-5}$	0,625	Riesgo	$1,92 \times 10^{-4}$
PTPN12	ENSG00000127947	yellow	1,586	1,287	1,954	$1,47 \times 10^{-5}$	0,622	Riesgo	$1,92 \times 10^{-4}$
RAB10	ENSG00000084733	yellow	1,548	1,270	1,887	$1,57 \times 10^{-5}$	0,634	Riesgo	$1,92 \times 10^{-4}$
AHNAK2	ENSG00000185567	yellow	1,665	1,321	2,099	$1,62 \times 10^{-5}$	0,639	Riesgo	$1,92 \times 10^{-4}$

CDH3	ENSG00000062038	yellow	1,600	1,288	1,989	$2,26 \times 10^{-5}$	0,615	Riesgo	$2,54 \times 10^{-4}$
FLNB	ENSG00000136068	yellow	1,548	1,262	1,899	$2,75 \times 10^{-5}$	0,625	Riesgo	$2,82 \times 10^{-4}$
COL17A1	ENSG00000065618	yellow	1,633	1,298	2,054	$2,75 \times 10^{-5}$	0,622	Riesgo	$2,82 \times 10^{-4}$
LRRC8E	ENSG00000171017	yellow	1,515	1,246	1,841	$3,02 \times 10^{-5}$	0,605	Riesgo	$2,95 \times 10^{-4}$
LAMC2	ENSG00000058085	yellow	1,732	1,337	2,245	$3,29 \times 10^{-5}$	0,604	Riesgo	$2,96 \times 10^{-4}$
LINC03080	ENSG00000259341	yellow	1,489	1,234	1,797	$3,29 \times 10^{-5}$	0,586	Riesgo	$2,96 \times 10^{-4}$
SMAD3	ENSG00000166949	yellow	1,517	1,245	1,848	$3,64 \times 10^{-5}$	0,610	Riesgo	$3,15 \times 10^{-4}$
B4GALT5	ENSG00000158470	yellow	1,467	1,222	1,761	$3,88 \times 10^{-5}$	0,618	Riesgo	$3,22 \times 10^{-4}$
LINC01559	ENSG00000180861	yellow	1,551	1,258	1,913	$4,01 \times 10^{-5}$	0,607	Riesgo	$3,22 \times 10^{-4}$
YWHAZ	ENSG00000164924	yellow	1,506	1,237	1,833	$4,38 \times 10^{-5}$	0,626	Riesgo	$3,40 \times 10^{-4}$
LIPH	ENSG00000163898	yellow	1,661	1,301	2,122	$4,81 \times 10^{-5}$	0,610	Riesgo	$3,61 \times 10^{-4}$
DIAPH1	ENSG00000131504	yellow	1,475	1,221	1,781	$5,42 \times 10^{-5}$	0,622	Riesgo	$3,74 \times 10^{-4}$
PROM2	ENSG00000155066	yellow	1,604	1,275	2,018	$5,59 \times 10^{-5}$	0,626	Riesgo	$3,74 \times 10^{-4}$
MKI67	ENSG00000148773	yellow	1,539	1,248	1,898	$5,70 \times 10^{-5}$	0,607	Riesgo	$3,74 \times 10^{-4}$
MMP28	ENSG00000271447	yellow	1,549	1,252	1,917	$5,70 \times 10^{-5}$	0,622	Riesgo	$3,74 \times 10^{-4}$
ASPH	ENSG00000198363	yellow	1,477	1,221	1,786	$5,92 \times 10^{-5}$	0,612	Riesgo	$3,74 \times 10^{-4}$
ANXA3	ENSG00000138772	yellow	1,713	1,317	2,229	$6,04 \times 10^{-5}$	0,629	Riesgo	$3,74 \times 10^{-4}$
KATNAL2	ENSG00000167216	red	0,569	0,432	0,750	$6,17 \times 10^{-5}$	0,627	Protector	$3,74 \times 10^{-4}$
ITGA2	ENSG00000164171	yellow	1,562	1,255	1,943	$6,41 \times 10^{-5}$	0,614	Riesgo	$3,74 \times 10^{-4}$
TBL1XR1	ENSG00000177565	yellow	1,523	1,239	1,872	$6,49 \times 10^{-5}$	0,591	Riesgo	$3,74 \times 10^{-4}$
SLC44A2	ENSG00000129353	yellow	1,590	1,265	1,999	$7,13 \times 10^{-5}$	0,616	Riesgo	$3,98 \times 10^{-4}$
ANXA2	ENSG00000182718	yellow	1,677	1,299	2,165	$7,25 \times 10^{-5}$	0,630	Riesgo	$3,98 \times 10^{-4}$
PTBP3	ENSG00000119314	yellow	1,450	1,205	1,744	$8,38 \times 10^{-5}$	0,607	Riesgo	$4,49 \times 10^{-4}$

ZDHH C5	ENSG0000 0156599	yell ow	1,531	1,238	1,894	$8,67 \times 10^{-5}$	0,594	Riesgo	$4,54 \times 10^{-4}$
SPATS 2L	ENSG0000 0196141	yell ow	1,712	1,307	2,242	$9,40 \times 10^{-5}$	0,604	Riesgo	$4,81 \times 10^{-4}$
MPZL 2	ENSG0000 0149573	yell ow	1,496	1,221	1,834	$1,04 \times 10^{-4}$	0,641	Riesgo	$5,19 \times 10^{-4}$
CTNN A1	ENSG0000 0044115	yell ow	1,541	1,238	1,919	$1,10 \times 10^{-4}$	0,616	Riesgo	$5,29 \times 10^{-4}$
SLK	ENSG0000 0065613	yell ow	1,437	1,196	1,727	$1,11 \times 10^{-4}$	0,617	Riesgo	$5,29 \times 10^{-4}$
GPRC 5A	ENSG0000 0013588	yell ow	1,637	1,273	2,104	$1,20 \times 10^{-4}$	0,619	Riesgo	$5,61 \times 10^{-4}$
EPHA 2	ENSG0000 0142627	yell ow	1,509	1,222	1,863	$1,31 \times 10^{-4}$	0,599	Riesgo	$6,02 \times 10^{-4}$
EIF4G 1	ENSG0000 0114867	yell ow	1,413	1,182	1,689	$1,46 \times 10^{-4}$	0,601	Riesgo	$6,59 \times 10^{-4}$
NIPSN AP3B	ENSG0000 0165028	red	0,673	0,549	0,827	$1,58 \times 10^{-4}$	0,619	Protector	$6,96 \times 10^{-4}$
CAPN 1	ENSG0000 0014216	yell ow	1,503	1,214	1,861	$1,84 \times 10^{-4}$	0,614	Riesgo	$7,95 \times 10^{-4}$
LAMB 3	ENSG0000 0196878	yell ow	1,610	1,254	2,066	$1,88 \times 10^{-4}$	0,606	Riesgo	$7,96 \times 10^{-4}$
TM4S F1	ENSG0000 0169908	yell ow	1,536	1,226	1,924	$1,91 \times 10^{-4}$	0,612	Riesgo	$7,96 \times 10^{-4}$
ITGA3	ENSG0000 0005884	yell ow	1,486	1,205	1,834	$2,15 \times 10^{-4}$	0,635	Riesgo	$8,76 \times 10^{-4}$
PSCA	ENSG0000 0167653	yell ow	1,455	1,193	1,774	$2,18 \times 10^{-4}$	0,610	Riesgo	$8,76 \times 10^{-4}$
FERM T1	ENSG0000 0101311	yell ow	1,491	1,205	1,846	$2,39 \times 10^{-4}$	0,597	Riesgo	$9,40 \times 10^{-4}$
MIR60 OHG	ENSG0000 0236901	red	0,539	0,387	0,750	$2,42 \times 10^{-4}$	0,603	Protector	$9,40 \times 10^{-4}$
LINC0 2577	ENSG0000 0228742	yell ow	1,449	1,187	1,769	$2,68 \times 10^{-4}$	0,608	Riesgo	0,0010
ZNF23 2-AS1	ENSG0000 0234327	red	0,613	0,471	0,798	$2,74 \times 10^{-4}$	0,575	Protector	0,0010
KRT19	ENSG0000 0171345	yell ow	1,651	1,260	2,163	$2,79 \times 10^{-4}$	0,628	Riesgo	0,0010
ERO1 A	ENSG0000 0197930	yell ow	1,408	1,170	1,694	$3,00 \times 10^{-4}$	0,616	Riesgo	0,0011
MGLL	ENSG0000 0074416	yell ow	1,465	1,191	1,802	$3,03 \times 10^{-4}$	0,589	Riesgo	0,0011
LMO7	ENSG0000 0136153	yell ow	1,472	1,193	1,816	$3,07 \times 10^{-4}$	0,605	Riesgo	0,0011
ITGA6	ENSG0000 0091409	yell ow	1,487	1,198	1,846	$3,25 \times 10^{-4}$	0,599	Riesgo	0,0011

APOL 1	ENSG0000 0100342	yell ow	1,452	1,185	1,779	$3,29 \times 10^{-4}$	0,609	Riesgo	0,0011
KLF5	ENSG0000 0102554	yell ow	1,520	1,209	1,910	$3,37 \times 10^{-4}$	0,592	Riesgo	0,0011
SYPL1	ENSG0000 0008282	yell ow	1,414	1,168	1,712	$3,92 \times 10^{-4}$	0,611	Riesgo	0,0013
CDCP 1	ENSG0000 0163814	yell ow	1,472	1,188	1,825	$4,15 \times 10^{-4}$	0,606	Riesgo	0,0014
	ENSG0000 0266947	red	0,661	0,524	0,833	$4,69 \times 10^{-4}$	0,584	Protector	0,0015
	ENSG0000 0274712	red	0,619	0,473	0,810	$4,79 \times 10^{-4}$	0,610	Protector	0,0015
PCDH 1	ENSG0000 0156453	yell ow	1,485	1,189	1,854	$4,92 \times 10^{-4}$	0,611	Riesgo	0,0015
S100A 16	ENSG0000 0188643	yell ow	1,463	1,180	1,814	$5,29 \times 10^{-4}$	0,600	Riesgo	0,0016
SDC4	ENSG0000 0124145	yell ow	1,476	1,184	1,841	$5,42 \times 10^{-4}$	0,598	Riesgo	0,0016
PDCD 6IP	ENSG0000 0170248	yell ow	1,376	1,148	1,649	$5,45 \times 10^{-4}$	0,599	Riesgo	0,0016
ITGB4	ENSG0000 0132470	yell ow	1,484	1,186	1,857	$5,58 \times 10^{-4}$	0,598	Riesgo	0,0017
PERP	ENSG0000 0112378	yell ow	1,432	1,167	1,758	$5,91 \times 10^{-4}$	0,618	Riesgo	0,0017
GPX3	ENSG0000 0211445	red	0,681	0,547	0,848	$6,04 \times 10^{-4}$	0,583	Protector	0,0017
	ENSG0000 0272501	red	0,673	0,536	0,844	$6,21 \times 10^{-4}$	0,543	Protector	0,0018
ELOV L1	ENSG0000 0066322	yell ow	1,343	1,132	1,593	$7,00 \times 10^{-4}$	0,580	Riesgo	0,0020
SDR1 6C5	ENSG0000 0170786	yell ow	1,392	1,149	1,687	$7,36 \times 10^{-4}$	0,590	Riesgo	0,0020
EZR	ENSG0000 0092820	yell ow	1,413	1,156	1,728	$7,54 \times 10^{-4}$	0,578	Riesgo	0,0021
TRIM2 9	ENSG0000 0137699	yell ow	1,453	1,168	1,809	$8,04 \times 10^{-4}$	0,597	Riesgo	0,0022
ALDH 3B1	ENSG0000 0006534	yell ow	1,394	1,147	1,694	$8,27 \times 10^{-4}$	0,611	Riesgo	0,0022
ZDHH C20	ENSG0000 0180776	yell ow	1,408	1,152	1,721	$8,38 \times 10^{-4}$	0,582	Riesgo	0,0022
PSEN 1	ENSG0000 0080815	yell ow	1,420	1,155	1,746	$8,81 \times 10^{-4}$	0,589	Riesgo	0,0023
TMBI M1	ENSG0000 0135926	yell ow	1,402	1,148	1,713	$9,23 \times 10^{-4}$	0,584	Riesgo	0,0024
UGT1 A10	ENSG0000 0242515	yell ow	1,407	1,148	1,725	0,0010	0,585	Riesgo	0,0026

LDLR	ENSG00000130164	yellow	1,383	1,139	1,679	0,0010	0,575	Riesgo	0,0026
LINC02908	ENSG00000180539	red	0,668	0,525	0,851	0,0011	0,606	Protector	0,0026
PADI1	ENSG00000142623	yellow	1,373	1,135	1,661	0,0011	0,608	Riesgo	0,0027
HNRNPF	ENSG00000169813	yellow	1,369	1,133	1,655	0,0011	0,585	Riesgo	0,0027
PLCD3	ENSG00000161714	yellow	1,381	1,137	1,677	0,0011	0,601	Riesgo	0,0027
CAPN2	ENSG00000162909	yellow	1,398	1,140	1,713	0,0013	0,603	Riesgo	0,0030
SCNN1A	ENSG00000111319	yellow	1,343	1,120	1,611	0,0015	0,613	Riesgo	0,0035
HMGA1	ENSG00000137309	yellow	1,320	1,112	1,568	0,0015	0,600	Riesgo	0,0035
	ENSG00000272379	red	0,637	0,481	0,843	0,0016	0,604	Protector	0,0037
CTTN	ENSG00000085733	yellow	1,390	1,133	1,705	0,0016	0,597	Riesgo	0,0037
ZDHC3	ENSG00000163812	yellow	1,341	1,117	1,610	0,0016	0,583	Riesgo	0,0037
TNFRSF21	ENSG00000146072	yellow	1,463	1,154	1,854	0,0017	0,599	Riesgo	0,0037
SFXN3	ENSG00000107819	yellow	1,387	1,130	1,702	0,0017	0,591	Riesgo	0,0039
MAL2	ENSG00000147676	yellow	1,424	1,140	1,778	0,0018	0,607	Riesgo	0,0040
S100A14	ENSG00000189334	yellow	1,343	1,114	1,618	0,0020	0,595	Riesgo	0,0043
CORO2A	ENSG00000106789	yellow	1,378	1,125	1,689	0,0020	0,557	Riesgo	0,0043
SLC2A1	ENSG00000117394	yellow	1,365	1,120	1,664	0,0020	0,590	Riesgo	0,0044
C10orf143	ENSG00000237489	red	0,715	0,577	0,885	0,0021	0,598	Protector	0,0044
CRIP3	ENSG00000146215	red	0,692	0,547	0,875	0,0021	0,556	Protector	0,0044
C14orf180	ENSG00000184601	red	0,635	0,475	0,848	0,0021	0,585	Protector	0,0044
LRRC8A	ENSG00000136802	yellow	1,338	1,110	1,611	0,0022	0,598	Riesgo	0,0045
B3GNT3	ENSG00000179913	yellow	1,423	1,135	1,783	0,0022	0,612	Riesgo	0,0045
UBE2H	ENSG00000186591	yellow	1,351	1,114	1,638	0,0022	0,609	Riesgo	0,0045

BCL2L1	ENSG00000171552	yellow	1,329	1,107	1,597	0,0024	0,606	Riesgo	0,0047
KRT18	ENSG00000111057	yellow	1,393	1,125	1,724	0,0024	0,605	Riesgo	0,0047
TOB1	ENSG00000141232	yellow	1,379	1,120	1,697	0,0024	0,604	Riesgo	0,0048
TSPAN1	ENSG00000117472	yellow	1,435	1,132	1,817	0,0028	0,594	Riesgo	0,0055
NIBAN2	ENSG00000136830	yellow	1,373	1,115	1,691	0,0029	0,584	Riesgo	0,0056
PDCD4-AS1	ENSG00000203497	red	0,687	0,537	0,880	0,0029	0,593	Protector	0,0056
APLP2	ENSG00000084234	yellow	1,340	1,104	1,627	0,0031	0,598	Riesgo	0,0059
RAB11A	ENSG00000103769	yellow	1,359	1,108	1,667	0,0032	0,601	Riesgo	0,0061
NHSL3	ENSG00000162522	yellow	1,378	1,111	1,709	0,0035	0,565	Riesgo	0,0066
MBOAT2	ENSG00000143797	yellow	1,355	1,105	1,661	0,0036	0,594	Riesgo	0,0066
SCN4A	ENSG00000007314	red	0,685	0,531	0,885	0,0037	0,599	Protector	0,0069
MYH3	ENSG00000109063	red	0,733	0,594	0,905	0,0039	0,575	Protector	0,0071
COLQ	ENSG00000206561	red	0,729	0,587	0,905	0,0042	0,561	Protector	0,0076
OCIA D2	ENSG00000145247	yellow	1,368	1,102	1,699	0,0045	0,580	Riesgo	0,0081
STAU1	ENSG00000124214	yellow	1,348	1,096	1,657	0,0046	0,570	Riesgo	0,0082
ABHD17C	ENSG00000136379	yellow	1,329	1,090	1,620	0,0050	0,578	Riesgo	0,0088
CCND1	ENSG00000110092	yellow	1,297	1,081	1,555	0,0050	0,591	Riesgo	0,0088
PTTG1IP	ENSG00000183255	yellow	1,310	1,082	1,586	0,0056	0,584	Riesgo	0,0098
	ENSG00000280434	red	0,702	0,546	0,902	0,0058	0,579	Protector	0,0100
	ENSG00000272927	red	0,734	0,589	0,914	0,0058	0,572	Protector	0,0100
PGK1	ENSG00000102144	yellow	1,296	1,075	1,564	0,0067	0,596	Riesgo	0,0114
CUX2	ENSG00000111249	red	0,489	0,291	0,821	0,0068	0,612	Protector	0,0116
IRF6	ENSG00000117595	yellow	1,353	1,086	1,685	0,0070	0,591	Riesgo	0,0118

LRRFI P1	ENSG0000 0124831	yell ow	1,244	1,056	1,466	0,0089	0,601	Riesgo	0,0149
FAM8 3H	ENSG0000 0180921	yell ow	1,310	1,068	1,607	0,0095	0,601	Riesgo	0,0156
SLC6 A16	ENSG0000 0063127	red	0,738	0,587	0,929	0,0095	0,540	Protector	0,0156
ERBB 3	ENSG0000 0065361	yell ow	1,344	1,071	1,687	0,0108	0,565	Riesgo	0,0176
PYGB	ENSG0000 0100994	yell ow	1,270	1,052	1,534	0,0130	0,590	Riesgo	0,0210
TAGL N2	ENSG0000 0158710	yell ow	1,266	1,050	1,527	0,0133	0,576	Riesgo	0,0214
C1orf1 16	ENSG0000 0182795	yell ow	1,341	1,061	1,696	0,0141	0,577	Riesgo	0,0226
LINC0 1619	ENSG0000 0257242	red	0,601	0,399	0,906	0,0151	0,592	Protector	0,0239
PHAC TR1	ENSG0000 0112137	red	0,750	0,594	0,947	0,0155	0,582	Protector	0,0244
PSMD 1	ENSG0000 0173692	yell ow	1,267	1,043	1,539	0,0173	0,556	Riesgo	0,0271
CDH1	ENSG0000 0039068	yell ow	1,343	1,051	1,715	0,0182	0,571	Riesgo	0,0282
RIOK3	ENSG0000 0101782	yell ow	1,247	1,038	1,499	0,0187	0,572	Riesgo	0,0287
IGFLR 1	ENSG0000 0126246	red	0,723	0,550	0,949	0,0195	0,583	Protector	0,0298
PRCD	ENSG0000 0214140	red	0,739	0,573	0,953	0,0196	0,581	Protector	0,0298
NMU	ENSG0000 0109255	yell ow	1,255	1,036	1,521	0,0201	0,578	Riesgo	0,0304
PKM	ENSG0000 0067225	yell ow	1,263	1,029	1,549	0,0253	0,591	Riesgo	0,0379
RHOB TB2-A S1	ENSG0000 0245025	red	0,784	0,631	0,976	0,0291	0,576	Protector	0,0433
CA9	ENSG0000 0107159	yell ow	1,233	1,020	1,490	0,0301	0,569	Riesgo	0,0446
TAX1B P1	ENSG0000 0106052	yell ow	1,211	1,017	1,442	0,0318	0,581	Riesgo	0,0467
ZBTB3 2	ENSG0000 0011590	red	0,737	0,557	0,976	0,0333	0,593	Protector	0,0487